Estudio de la Estabilidad de Métodos de Explicabilidad (XAI) en Graph Neural Networks para Detección de Lavado de Dinero bajo Desbalance Extremo de Datos

Alejandro Gómez Huertas
Juan Diego Garzón Ovalle

Universidad Tecnológica de Pereira
Facultad de Ingenierías
Maestría en Ingeniería en Sistemas y Computación
Pereira, Colombia
2026

Estudio de la Estabilidad de Métodos de Explicabilidad (XAI) en Graph Neural Networks para Detección de Lavado de Dinero bajo Desbalance Extremo de Datos

Alejandro Gómez Huertas
Juan Diego Garzón Ovalle

Tesis de grado presentada como requisito parcial para optar al título de:

Magíster en Ingeniería en Sistemas y Computación

Director
Ph.D. Cristian Rosero

Universidad Tecnológica de Pereira
Facultad de Ingenierías
Maestría en Ingeniería en Sistemas y Computación
Pereira, Colombia
2026

Índice general

Índice de figuras **v**

Índice de tablas **vi**

1 INTRODUCCIÓN **1**
1.1 Planteamiento y Contexto del Problema 1
1.2 Revisión de Literatura y Estado del Arte 3
1.3 Brecha de Investigación 4
1.4 Formulación del Problema 6
1.5 Objetivos 7
1.5.1 Objetivo General 7
1.5.2 Objetivos Específicos 8
1.6 Justificación 8
1.6.1 Justificación Económica y Operativa 8
1.6.2 Justificación Tecnológica 8
1.6.3 Justificación Científica y Social 9
1.7 Alcance y Limitaciones 9
1.8 Estructura de la Tesis 10

2 MARCO CONTEXTUAL **11**
2.1 El Lavado de Dinero como Fenómeno Financiero Global 11
2.1.1 Definición y naturaleza del lavado de activos 11
2.1.2 Las tres etapas del lavado de dinero 12
2.2 Marco Regulatorio Internacional Anti-Lavado de Activos 12
2.2.1 El Grupo de Acción Financiera Internacional (GAFI/FATF) . . . 12
2.2.2 Regulación de activos virtuales y la Regla de Viaje 13
2.2.3 Enfoque de Gestión de Riesgos del Comité de Basilea 14
2.2.4 Debida Diligencia del Cliente (KYC) 14
2.3 Sistemas Tradicionales de Monitoreo de Transacciones 14
2.3.1 Arquitectura de los sistemas basados en reglas 14
2.3.2 El problema de los falsos positivos 14
2.3.3 Costos del cumplimiento AML 15
2.4 Criptomonedas y Delincuencia Financiera 16
2.4.1 Seudonimato y arquitectura descentralizada 16
2.4.2 Magnitud de la actividad ilícita en criptomonedas 16
2.5 Tipologías de Lavado de Dinero en Criptomonedas 16
2.5.1 Mezcladores y servicios de ofuscación 16
2.5.2 Cadenas de pelado (*Peel Chains*) 16

2.5.3 Saltos de cadena y puentes entre *blockchains* 17
2.5.4 Otras técnicas de lavado en criptomonedas 17
2.5.5 Comparación de técnicas de lavado 17
2.6 Desafíos de la Detección de Fraude Financiero en el Ecosistema Cripto . 17
2.6.1 Desafíos operativos y regulatorios 17
2.6.2 La brecha entre regulación y realidad operativa 18
2.7 Del Monitoreo Basado en Reglas hacia Enfoques Estructurales 19
2.7.1 Limitaciones fundamentales del enfoque tabular 19
2.7.2 Transacciones financieras como grafos 19
2.7.3 El Elliptic Dataset como referente 19
2.7.4 Hacia la necesidad de modelos explicables 19

3 FUNDAMENTOS DE IA PARA DETECCIÓN DE FRAUDE FINANCIERO 21
3.1 Del Aprendizaje Automático al Aprendizaje Profundo 21
3.1.1 Aprendizaje Automático: Definición y Paradigmas 21
3.1.2 Limitaciones del ML Tabular en Detección AML 22
3.1.3 El Aprendizaje Profundo como Paradigma de Representación . . 22
3.2 Graph Neural Networks: Fundamentos Conceptuales 23
3.2.1 Representación de Datos Financieros como Grafos 23
3.2.2 El Paradigma de Message Passing 23
3.2.3 Ventajas de las GNNs en Detección AML 24
3.3 Arquitecturas GNN Evaluadas 24
3.3.1 Graph Convolutional Networks (GCN) 24
3.3.2 GraphSAGE: Aprendizaje Inductivo y Muestreo de Vecindarios . 25
3.3.3 Graph Attention Networks (GAT) 25
3.3.4 TAGCN: Convolución Adaptativa por Topología 26
3.3.5 Síntesis Comparativa de Arquitecturas 26
3.4 El Desafío de la Explicabilidad en GNNs 27
3.4.1 Necesidad de Interpretabilidad en Contextos Regulados 27
3.4.2 GNNExplainer: Explicación por Optimización Local 27
3.4.3 PGExplainer: Explicación Parametrizada 28
3.4.4 GNNShap: Explicación Basada en Valores de Shapley 28
3.4.5 El Problema de la Estabilidad Explicativa 28
3.5 Estrategias de Mitigación del Desbalance de Clases 29
3.5.1 El Problema del Desbalance en Detección AML 29
3.5.2 GraphSMOTE: Sobremuestreo Topológico 29
3.5.3 Ponderación de Clases y Funciones de Pérdida 29
3.6 Formalización de Métricas de Evaluación 30
3.6.1 Métricas Fundamentales de Clasificación 30
3.6.2 Métricas de Rendimiento Predictivo en Escenarios de Desbalance 31
3.6.3 Métricas de Estabilidad y Fidelidad Explicativa 31
3.7 Preparación para el Diseño Experimental 32

4 METODOLOGÍA 33
4.1 Conjunto de Datos: Elliptic Bitcoin Dataset 33
4.1.1 Descripción General y Procedencia 33
4.1.2 División Temporal de los Datos 34
4.1.3 Normalización de Atributos 34

4.2 Construcción de los Escenarios de Desbalance 34
4.2.1 Justificación de los Escenarios 34
4.2.2 Escenarios Definidos 35
4.3 Arquitecturas GNN Evaluadas 35
4.3.1 Configuración Común 35
4.3.2 GCN (Graph Convolutional Network) 36
4.3.3 GraphSAGE (Sample and Aggregate) 36
4.3.4 GAT (Graph Attention Network) 36
4.3.5 TAGCN (Topology Adaptive Graph Convolutional Network) . . . 36
4.4 Técnicas de Mitigación del Desbalance 36
4.4.1 Línea Base Sin Balanceo 36
4.4.2 Ponderación de Clases (Class Weighting) 37
4.4.3 Focal Loss 37
4.4.4 Exclusión de GraphSMOTE 37
4.5 Métodos de Explicabilidad (XAI) 37
4.5.1 Selección de Nodos a Explicar 37
4.5.2 Configuración de GNNExplainer 38
4.5.3 Configuración de PGExplainer 38
4.5.4 Configuración de GNNShap 38
4.6 Protocolo de Evaluación de Estabilidad 38
4.6.1 Test Estocástico (Stochastic Stability) 38
4.6.2 Test de Perturbación (Perturbation Stability) 39
4.6.3 Extracción de Subgrafos y Rankings 39
4.7 Métricas de Evaluación 39
4.7.1 Métricas Predictivas 39
4.7.2 Métricas de Estabilidad 40
4.8 Optimización de Hiperparámetros 40
4.9 Infraestructura Computacional y Distribución de la Carga 40
4.9.1 Configuración de Máquinas 40
4.9.2 Reproducibilidad y Reanudación 41
4.9.3 Tracking y Registro de Resultados 41
4.10 Análisis Estadístico 41
4.10.1 ANOVA Factorial 41
4.10.2 Comparaciones Post-Hoc 42
4.10.3 Matriz de Recomendación 42
4.11 Síntesis del Diseño Metodológico 42

5 RESULTADOS 43
5.1 Análisis Exploratorio de Datos 43
5.2 Descripción del Pipeline Experimental 43
5.2.1 Configuración de hiperparámetros 43
5.2.2 Infraestructura computacional 43
5.3 Escenarios de Desbalance 43
5.4 Resultados de Rendimiento Predictivo 43
5.4.1 Impacto del desbalance en el rendimiento 43
5.4.2 Comparación entre arquitecturas 43
5.4.3 Efecto de las técnicas de balanceo 43
5.5 Resultados de Estabilidad Explicativa 43

5.5.1 Estabilidad estocástica 43
5.5.2 Estabilidad ante perturbaciones 43
5.5.3 Fidelidad de las explicaciones 43
5.6 Análisis Factorial 43
5.7 Síntesis de Resultados 43

6 DISCUSIÓN 44
6.1 Degradación de la Estabilidad Explicativa bajo Desbalance 44
6.2 Resiliencia Arquitectónica: GCN vs. GraphSAGE vs. GAT vs. TAGCN . 44
6.3 Impacto de las Estrategias de Balanceo sobre la Explicabilidad 44
6.4 Comparación entre Explicadores: GNNExplainer, PGExplainer y GNNShap 44
6.5 Hacia una Tríada Óptima 44
6.6 Implicaciones para la Industria AML 44
6.7 Limitaciones del Estudio 44

7 CONCLUSIONES 45
7.1 Respuestas a los Objetivos de Investigación 45
7.1.1 Sobre el impacto del desbalance en la estabilidad explicativa . . . 45
7.1.2 Sobre la resiliencia topológica de las arquitecturas GNN 45
7.1.3 Sobre el impacto de las estrategias de mitigación del desbalance . 45
7.1.4 Sobre la matriz de recomendación técnica 45
7.2 Contribuciones Principales 45
7.3 Limitaciones Identificadas 45

8 PERSPECTIVAS FUTURAS Y ANEXOS 46
8.1 Perspectivas Futuras 46
8.1.1 Extensión a otros conjuntos de datos y dominios 46
8.1.2 Incorporación de GraphSMOTE y técnicas de sobremuestreo topológico 46
8.1.3 Arquitecturas dinámicas y temporales 46
8.1.4 Métricas de estabilidad adicionales 46
8.1.5 Integración con sistemas operativos de cumplimiento 46
8.1.6 Explicabilidad interactiva y centrada en el usuario 46

Referencias 47

Índice de figuras

2.1 Diagrama de flujo que ilustra las tres etapas clásicas del lavado de dinero: colocación, estratificación e integración. 13
2.2 Comparación entre monitoreo transaccional basado en reglas, con umbrales estáticos y hasta 90–98% de falsos positivos, y un enfoque relacional basado en grafos, donde las transacciones se analizan como redes para detectar patrones estructurales sospechosos. 15

Índice de tablas

1.1 Síntesis del estado del arte en detección AML basada en grafos y explicabilidad. 5

2.1 Principales técnicas de lavado de dinero en criptomonedas, clasificadas por etapa, mecanismo y complejidad de detección. 18

Capítulo 1

INTRODUCCIÓN

1.1 Planteamiento y Contexto del Problema

El lavado de dinero, designado en la literatura internacional como *Anti-Money Laundering* (AML), constituye uno de los mecanismos centrales mediante los cuales las economías criminales logran insertar recursos ilícitos dentro de los circuitos financieros formales. Este fenómeno no solo facilita la circulación de capitales provenientes del narcotráfico, la trata de personas, el tráfico de armas, la corrupción o el financiamiento del terrorismo, sino que además erosiona la estabilidad institucional, distorsiona los mercados y debilita la confianza en los sistemas de supervisión financiera. Su magnitud ha dejado de ser un asunto exclusivamente policial para convertirse en un problema económico y regulatorio de escala global. En este sentido, la Oficina de las Naciones Unidas contra la Droga y el Delito (UNODC) estima que los flujos financieros ilícitos representan entre el 2% y el 5% del Producto Interno Bruto mundial, lo cual equivale a montos cercanos a los 2 billones de dólares anuales [1].

En el caso particular de las criptomonedas, el problema adquiere una complejidad adicional. La arquitectura descentralizada de los sistemas *blockchain*, la facilidad para transferir valor de forma transfronteriza, el seudonimato de las direcciones y la ausencia de intermediarios tradicionales han creado un entorno propicio para la circulación, fragmentación y ocultamiento de fondos ilícitos [2, 3]. A esto se suma la sofisticación creciente de las técnicas de lavado basadas en criptoactivos, las cuales ya no se limitan a transferencias simples, sino que incluyen estrategias de dispersión, mezcla, integración y transacciones encadenadas que aprovechan la estructura de red de los ecosistemas digitales [4]. Como resultado, la detección de operaciones sospechosas en este contexto exige modelos capaces de comprender relaciones dinámicas y patrones estructurales más allá del análisis aislado de transacciones individuales.

Las instituciones financieras y los *exchanges* de criptomonedas continúan dependiendo, en gran medida, de Sistemas de Monitoreo de Transacciones (TMS) convencionales, sustentados en reglas deterministas, listas de vigilancia y umbrales estáticos. Aunque estas herramientas han sido la base del cumplimiento normativo durante décadas, su capacidad para responder a tipologías modernas de lavado es limitada. El principal problema radica en que tratan las transacciones como eventos independientes, ignorando la topología relacional entre cuentas, billeteras y flujos monetarios. Esto produce un ruido operativo masivo: diversos estudios reportan que entre el 95% y el 98% de las alertas generadas por estos sistemas corresponden a falsos positivos [5]. En consecuencia, los equipos de cumplimiento deben invertir enormes cantidades de tiempo y recursos en la revisión

manual de alertas irrelevantes, mientras que los patrones verdaderamente sofisticados logran mimetizarse dentro del volumen general de actividad financiera.
Este problema de ineficiencia no es únicamente técnico, sino también económico y estratégico. Los falsos positivos elevan de manera desproporcionada los costos de operación, reducen la capacidad de respuesta analítica de las instituciones y generan fatiga organizacional en los procesos de monitoreo. Más grave aún, desplazan la atención desde los casos realmente relevantes hacia señales espurias que no representan riesgo material. En otras palabras, un sistema que produce demasiadas alertas incorrectas no solo falla por exceso, sino también por omisión: al saturar la capacidad investigativa, incrementa la probabilidad de que operaciones ilícitas genuinas pasen desapercibidas [3, 5]. Esta realidad ha impulsado la búsqueda de modelos más robustos que puedan capturar estructuras complejas de interacción financiera sin depender exclusivamente de reglas manuales.
En este escenario, las *Graph Neural Networks* (GNNs) han emergido como un paradigma prometedor para el dominio AML. A diferencia de los modelos tabulares tradicionales, las GNNs explotan explícitamente la naturaleza relacional de los datos financieros, representando las transacciones y entidades como nodos, y sus vínculos como aristas dentro de un grafo. Esta formulación permite aprender patrones topológicos que serían invisibles para modelos clásicos, tales como vecindarios sospechosos, cadenas de dispersión, ciclos transaccionales o estructuras de intermediación artificial [6, 7]. Los trabajos pioneros sobre el *Elliptic Dataset* mostraron que el modelado basado en grafos supera a varios enfoques convencionales en la detección de transacciones ilícitas sobre redes de Bitcoin, precisamente porque integra información estructural y contextual en el proceso de clasificación [6].
La evolución reciente de este campo ha dado lugar a arquitecturas aún más especializadas. Modelos híbridos que integran dinámicas temporales y convoluciones sobre grafos han mostrado que la detección AML mejora cuando se considera simultáneamente la dependencia estructural y la evolución secuencial de las transacciones [8, 9]. Asimismo, arquitecturas con mecanismos de atención y variantes de grafos evolutivos han ampliado la capacidad de capturar dependencias de largo alcance y cambios temporales en comportamientos ilícitos [10, 11]. Dentro de este ecosistema, TAGCN (*Topology Adaptive Graph Convolutional Network*) resulta particularmente relevante, ya que incorpora filtros polinomiales adaptativos capaces de agregar información desde múltiples saltos topológicos, lo que permite modelar dependencias más complejas que las capturadas por esquemas puramente locales [12, 13].
Sin embargo, el uso de GNNs en contextos regulados introduce una tensión crítica entre desempeño predictivo y auditabilidad. A pesar de su potencia analítica, estas arquitecturas funcionan como modelos altamente opacos, lo que dificulta comprender qué patrones concretos justifican una predicción de riesgo. En dominios como AML, esta opacidad es especialmente problemática, ya que las decisiones automatizadas pueden derivar en bloqueos de cuentas, reportes de operaciones sospechosas o investigaciones con implicaciones jurídicas y reputacionales significativas [1, 2]. Por ello, la exigencia contemporánea ya no es únicamente construir sistemas más precisos, sino desarrollar sistemas que además sean interpretables, auditables y defendibles frente a reguladores y equipos de cumplimiento.
En respuesta a esta necesidad, la Inteligencia Artificial Explicable (*Explainable AI*, XAI) se ha consolidado como una línea de investigación central para reducir la opacidad de los modelos complejos. En el caso de las GNNs, los métodos XAI buscan identificar qué nodos, aristas, atributos o subgrafos influyen de forma decisiva en una predicción concreta [14–17]. No obstante, la literatura reciente ha mostrado que la generación de explicaciones para modelos de grafos enfrenta limitaciones profundas asociadas con su fidelidad, robustez e inestabilidad. En particular, explicaciones obtenidas sobre una misma instancia pueden

variar considerablemente entre ejecuciones o bajo pequeñas perturbaciones, lo que cuestiona su confiabilidad como soporte analítico o forense [18–20]. Esta problemática constituye el núcleo conceptual de la presente investigación.

1.2 Revisión de Literatura y Estado del Arte

La literatura reciente sobre detección de lavado de dinero en criptomonedas muestra una evolución progresiva desde enfoques transaccionales convencionales hacia modelos estructurales basados en grafos. En una primera etapa, los trabajos se concentraron en adaptar algoritmos clásicos de clasificación al problema AML, utilizando atributos tabulares extraídos de cada transacción, como montos, frecuencia, temporalidad y estadísticas agregadas. Aunque estos métodos ofrecieron una base importante para automatizar el análisis de riesgo, su principal limitación fue la incapacidad de capturar la dependencia relacional entre transacciones y entidades, una dimensión central en las tipologías de lavado [5, 6].

El trabajo de Weber et al. constituye un punto de inflexión en esta línea, pues introdujo el uso del *Elliptic Dataset* como entorno de experimentación para modelos basados en grafos sobre transacciones Bitcoin. Su estudio mostró que representar la red de transacciones como un grafo permite capturar patrones estructurales que los modelos tabulares pierden, logrando mejoras consistentes en la clasificación de actividad ilícita [6]. Este aporte fue determinante porque transformó el problema AML desde una perspectiva centrada en instancias individuales hacia una perspectiva relacional, donde la posición de una transacción dentro de la red es tan importante como sus atributos intrínsecos.

A partir de este cambio de paradigma, surgieron múltiples variantes de GNNs aplicadas al dominio financiero. Lawal et al. propusieron un marco explicable para detección AML en criptomonedas utilizando el *Elliptic Dataset*, demostrando que los modelos de grafos no solo mejoran el rendimiento predictivo, sino que también pueden complementarse con mecanismos de explicabilidad post-hoc [7]. Por su parte, He et al. desarrollaron un marco explicable para la detección de transacciones financieras ilícitas, reforzando la idea de que el futuro de estos sistemas no pasa únicamente por maximizar métricas predictivas, sino por integrar interpretabilidad como componente esencial del diseño [13].

La investigación también ha explorado arquitecturas dinámicas e híbridas. Alarab y Prakoonwit estudiaron un modelo *graph-based LSTM* que combina componentes temporales con procesamiento estructural de grafos, mostrando que la dimensión temporal puede aportar valor cuando las actividades ilícitas se distribuyen a lo largo de secuencias transaccionales [8]. De manera similar, Wan y Li propusieron un modelo de predicción de lavado basado en una red convolucional dinámica sobre grafos y una arquitectura LSTM, reforzando la hipótesis de que el comportamiento ilícito no es estático, sino evolutivo [9]. Estos trabajos abren la puerta a sistemas más realistas para entornos donde las redes transaccionales cambian continuamente en el tiempo.

En paralelo, otros autores han investigado mecanismos de atención y aprendizaje estructural avanzado. Cui y Zhang presentaron EG-SAN, un modelo de autoatención sobre grafos evolutivos para detectar actividades ilícitas en criptomonedas, destacando el valor de ponderar selectivamente la relevancia de diferentes conexiones dentro de la red [10]. Lo et al. propusieron *Inspection-L*, un enfoque auto-supervisado para aprender representaciones de nodos aplicadas a la detección de lavado de dinero, lo cual evidencia que la literatura también avanza hacia estrategias menos dependientes de grandes cantidades de etiquetas

balanceadas [21]. Estas contribuciones confirman que la dirección del campo se orienta hacia arquitecturas cada vez más capaces de explotar la estructura topológica y temporal de las redes financieras.

No obstante, la evolución de las arquitecturas predictivas no ha sido acompañada de una evolución igualmente sólida en los mecanismos de validación explicativa. Los métodos XAI para GNNs han crecido rápidamente en número y diversidad, pero aún presentan desafíos importantes. GNNExplainer, propuesto por Ying et al., se consolidó como uno de los primeros métodos capaces de identificar subgrafos y atributos relevantes para justificar una predicción de GNN [15]. Posteriormente, PGExplainer introdujo un enfoque parametrizado que aprende un generador de explicaciones, mejorando escalabilidad y generalización frente a enfoques puramente locales [16]. Más recientemente, GNNShap adaptó la lógica de los valores de Shapley al contexto de grafos, buscando explicaciones más consistentes y teóricamente fundamentadas [17].

A pesar de estos avances, la literatura coincide en que explicar GNNs sigue siendo un problema abierto. Agarwal et al. realizaron un análisis riguroso de los métodos explicadores para GNNs y evidenciaron limitaciones tanto teóricas como prácticas en su capacidad para reflejar con precisión el razonamiento interno del modelo [19]. Kosan et al., mediante GNNX-BENCH, reforzaron esta crítica al demostrar que el desempeño de los explicadores depende fuertemente del criterio de evaluación utilizado, y que muchos resultados reportados en la literatura son sensibles al protocolo experimental [20]. En una línea complementaria, Armgaan et al. propusieron GnnXemplar como un marco sistemático para evaluar métodos de explicabilidad en redes de grafos, mostrando que muchas explicaciones consideradas plausibles no necesariamente son fieles o robustas [22].

En el dominio AML, esta limitación es todavía más delicada. No basta con que un explicador produzca un subgrafo visualmente coherente; es necesario que la explicación sea estable, reproducible y suficientemente fiel como para respaldar decisiones en escenarios regulados. Gawantka et al. propusieron una métrica específica para evaluar la estabilidad de las explicaciones XAI, subrayando que este criterio ha sido históricamente subestimado en la literatura [18]. A su vez, Rai et al. mostraron que el desbalance de clases puede deteriorar significativamente el comportamiento de las técnicas XAI, incluso cuando el modelo mantiene un desempeño predictivo aceptable [23]. Fujiwara profundizó en esta relación al estudiar cómo técnicas de remuestreo y destilación del conocimiento pueden mejorar simultáneamente el rendimiento predictivo y la estabilidad explicativa en escenarios desbalanceados [24].

En consecuencia, el estado del arte revela una convergencia clara: el problema AML en criptomonedas requiere modelos estructurales capaces de captar relaciones complejas, pero también exige mecanismos de explicabilidad cuya calidad no se mida únicamente por intuición visual o plausibilidad superficial. La combinación entre GNNs, XAI y desbalance extremo sigue siendo una zona insuficientemente explorada, especialmente cuando el criterio central de evaluación no es solo la exactitud de la clasificación, sino la estabilidad y auditabilidad de la explicación obtenida [5, 18, 23].

1.3 Brecha de Investigación

A pesar del avance significativo en la detección de lavado de dinero con modelos basados en grafos, la literatura actual exhibe una desconexión entre tres dimensiones que esta investigación considera necesario estudiar de manera integrada: el desbalance extremo de

Trabajo	**Enfoque principal**	**Aporte**	**Limitación relevante**
Weber et al. [6]	GCN sobre Bitcoin	Introduce el modelado relacional con Elliptic Dataset	Limitada atención a explicabilidad
Lawal et al. [7]	GNN explicable para AML	Integra predicción y explicación en cripto AML	No profundiza en estabilidad bajo desbalance extremo
He et al. [13]	Framework explicable para transacciones ilícitas	Refuerza la necesidad de interpretabilidad en finanzas	Requiere validación exhaustiva de robustez explicativa
Wan y Li [9]	GCN dinámica + LSTM	Modela dependencias estructurales y temporales	Mayor complejidad experimental
Cui y Zhang [10]	Autoatención en grafos evolutivos	Mejora detección en grafos dinámicos	Explicabilidad no es el foco central
Gawantka et al. [18]	Métrica de estabilidad XAI	Formaliza la evaluación de estabilidad explicativa	No se centra específicamente en AML
Rai et al. [23]	XAI bajo desbalance	Evidencia impacto del desbalance sobre explicaciones	Estudio en otro dominio, no sobre grafos AML
Fujiwara [24]	Remuestreo y estabilidad explicativa	Relaciona balanceo con estabilidad XAI	No aborda GNNs financieras de forma directa

Cuadro 1.1: Síntesis del estado del arte en detección AML basada en grafos y explicabilidad.

clases, la calidad de las explicaciones XAI y la robustez estructural de las arquitecturas GNN. Esta desconexión constituye la brecha central que motiva la presente tesis. Si bien existen trabajos que mejoran el rendimiento predictivo, trabajos que desarrollan explicadores para GNNs y trabajos que analizan estabilidad explicativa en otros dominios, todavía no existe una evaluación sistemática de cómo estas tres dimensiones interactúan en un entorno AML realista.

En primer lugar, el desbalance extremo de datos sigue siendo tratado de forma insuficiente. En los escenarios reales de monitoreo financiero, la clase ilícita representa una fracción mínima del total de transacciones, pudiendo llegar a razones cercanas a 1:1000 o incluso más severas dependiendo del contexto operacional [5, 23]. Sin embargo, una parte importante de la literatura experimental evalúa modelos en condiciones relativamente benignas, con particiones de datos que no reflejan la escasez real de eventos ilícitos. Esta simplificación puede inflar artificialmente el rendimiento del clasificador y ocultar el deterioro que ocurre cuando el sistema opera en ambientes altamente desbalanceados. Técnicas como GraphSMOTE han sido propuestas para clasificación desbalanceada en grafos, pero su efecto sobre la explicación generada por el modelo sigue siendo una cuestión abierta [25].

En segundo lugar, la literatura no ha resuelto satisfactoriamente el problema de la fidelidad y la estabilidad explicativa. La mayoría de los trabajos en XAI para grafos se ha enfocado en producir explicaciones plausibles o visualmente intuitivas, pero no necesariamente en demostrar que estas explicaciones son consistentes entre ejecuciones,

robustas frente a perturbaciones o verdaderamente representativas del mecanismo de decisión interno del modelo [19, 20, 22]. En contextos como AML, esta omisión es particularmente crítica, ya que una explicación inestable carece de valor operativo y jurídico. Una entidad financiera no puede sustentar una alerta de alto impacto en un subgrafo explicativo que cambia de forma sustancial cada vez que el explicador se ejecuta sobre la misma transacción.

En tercer lugar, la relación entre estrategias de mitigación del desbalance y calidad explicativa permanece subexplorada. Rai et al. y Fujiwara mostraron que el desbalance afecta no solo al clasificador, sino también a la consistencia de las explicaciones, y que ciertas técnicas de remuestreo pueden modificar esta relación [23, 24]. Sin embargo, estos hallazgos no se han extendido de forma rigurosa al dominio AML basado en grafos, donde la inserción de nodos sintéticos, el ajuste de pesos o el uso de funciones de pérdida especializadas podrían alterar la topología original y, con ello, introducir sesgos o artefactos en las explicaciones. En otras palabras, aún no está claro si balancear los datos mejora la comprensión del fenómeno ilícito o si, por el contrario, fabrica una representación más conveniente para el clasificador pero menos fiel al comportamiento real de la red financiera.

También existe una brecha comparativa entre arquitecturas. La literatura ha mostrado resultados prometedores con GCN, GraphSAGE, GAT, TAGCN, modelos temporales y modelos de atención, pero no ha establecido con claridad cuál de estas arquitecturas ofrece mejores garantías de interpretabilidad estable bajo condiciones severas de desbalance [6, 10–13]. El problema no consiste únicamente en identificar qué arquitectura clasifica mejor, sino en determinar cuál produce explicaciones más consistentes, robustas y utilizables en contextos regulatorios. Este es un vacío importante, porque una arquitectura con un desempeño predictivo ligeramente superior podría ser menos deseable si sus explicaciones son erráticas o frágiles.

En síntesis, la literatura no ha respondido de manera integral a la siguiente cuestión: ¿cómo se comportan los métodos XAI aplicados a distintas arquitecturas GNN para detección AML cuando el sistema enfrenta niveles extremos de desbalance, y qué combinación de arquitectura, explicador y estrategia de balanceo ofrece el mejor compromiso entre rendimiento predictivo y estabilidad explicativa? Esta ausencia de evidencia comparativa y metodológicamente rigurosa constituye la brecha específica que esta tesis busca cerrar.

1.4 Formulación del Problema

A partir del contexto presentado y de la revisión del estado del arte, se identifica un vacío de investigación en la evaluación rigurosa de la estabilidad de los métodos de explicabilidad aplicados a modelos GNN en escenarios AML caracterizados por desbalance extremo de datos. Este vacío no es menor: compromete la posibilidad de trasladar los avances en detección basada en grafos hacia entornos donde la auditabilidad, la reproducibilidad y la trazabilidad de la decisión son condiciones indispensables.

El problema no se reduce a mejorar métricas de clasificación. De hecho, una parte relevante de la literatura reciente ya ha mostrado que es posible obtener mejoras sustanciales en tareas de detección AML mediante arquitecturas de grafos, mecanismos de atención o modelos híbridos [7, 9, 11]. Sin embargo, cuando se introduce la dimensión explicativa, emergen limitaciones todavía no resueltas: las explicaciones pueden ser inestables, sensibles al ruido topológico, dependientes del método explicador e incluso afectadas por las estrategias

utilizadas para compensar el desbalance de clases [18, 23, 24]. En consecuencia, el problema científico de esta tesis se sitúa en la intersección entre clasificación, interpretabilidad y robustez.
Problema Principal: ¿Cómo evaluar y cuantificar la degradación de la estabilidad de los métodos de explicabilidad (XAI) en arquitecturas de *Graph Neural Networks* (GNNs) aplicadas a la detección de lavado de dinero en transacciones de Bitcoin sobre el *Elliptic Dataset*, bajo condiciones severas de desbalance de datos, y qué estrategias de balanceo y selección de modelos logran maximizar la estabilidad explicativa sin sacrificar el rendimiento predictivo?
Problemas Específicos:

1. ¿Cómo se cuantifica la degradación en la estabilidad de las explicaciones estructurales generadas por métodos XAI de diferente naturaleza, como GNNExplainer, PGExplainer y GNNShap, a medida que la razón de desbalance de clases se hace más extrema [15–17]?

2. ¿De qué manera las diferencias estructurales y mecanismos de agregación intrínsecos de diversas arquitecturas GNN, tales como GCN, GraphSAGE, GAT y TAGCN, condicionan la robustez de las explicaciones resultantes frente al ruido topológico presente en un grafo financiero [12, 13]?

3. ¿Cuál es el impacto colateral de implementar técnicas de sobremuestreo topológico o ajuste de pesos, como GraphSMOTE o funciones de pérdida orientadas al desbalance, sobre la interpretabilidad del modelo [25]?

4. ¿Es posible identificar una combinación sinérgica entre arquitectura de red, algoritmo explicador y estrategia de mitigación del desbalance que maximice simultáneamente la fidelidad predictiva y la estabilidad explicativa, sirviendo como referencia para sistemas AML auditables?

1.5 Objetivos

La presente investigación establece un marco de objetivos orientado a estudiar de manera sistemática la estabilidad de las explicaciones generadas por modelos GNN en escenarios AML con desbalance extremo. Más que proponer una mejora incremental en precisión, esta tesis busca construir evidencia robusta que permita entender el comportamiento explicativo de estas arquitecturas en condiciones cercanas a las del dominio real.

1.5.1 Objetivo General

Evaluar la estabilidad de los métodos de explicabilidad en Redes Neuronales de Grafos bajo condiciones extremas de desbalance de datos en la detección de lavado de dinero sobre el *Elliptic Dataset*, con el fin de proporcionar evidencia rigurosa y recomendaciones técnicas sobre las combinaciones óptimas de arquitectura, explicador y técnica de balanceo que garanticen explicaciones robustas, consistentes y auditables en entornos regulados.

1.5.2 Objetivos Específicos

1. Evaluar el impacto directo del desequilibrio de clases en la robustez de las explicaciones estructurales, ejecutando un análisis comparativo y cuantitativo de métodos representativos como GNNExplainer, PGExplainer y GNNShap a través de escenarios incrementales de submuestreo y desbalance en el *Elliptic Dataset* [15–17].

2. Comparar la resiliencia topológica de múltiples arquitecturas GNN, incluyendo GCN, GraphSAGE, GAT y TAGCN, midiendo la consistencia de los subgrafos explicativos generados bajo condiciones de estrés de datos [6, 12].

3. Analizar el impacto colateral de las estrategias de mitigación del desbalance, como ponderación de clases y *focal loss*, determinando mediante métricas de fidelidad y estabilidad si dichas intervenciones estabilizan o distorsionan la interpretación topológica del modelo [23, 24].

4. Construir y validar una matriz de recomendación técnica que articule rendimiento predictivo y estabilidad explicativa, proporcionando un marco de decisión fundamentado para el diseño de sistemas de detección AML basados en IA explicable.

1.6 Justificación

1.6.1 Justificación Económica y Operativa

El costo de la ineficiencia estructural en los sistemas AML actuales es extraordinariamente alto. Cuando entre el 95% y el 98% de las alertas generadas corresponden a falsos positivos, el gasto operativo asociado al cumplimiento normativo se incrementa de forma desproporcionada [5]. Esta carga no solo afecta a bancos tradicionales, sino también a plataformas de intercambio de activos virtuales, proveedores de servicios financieros digitales y equipos de investigación forense especializados en criptoactivos [2, 3]. Por tanto, cualquier avance que permita reducir el ruido operativo y dirigir mejor la atención analítica puede traducirse en beneficios tangibles en costos, eficiencia investigativa y capacidad institucional.
Desde esta perspectiva, una solución basada en GNNs explicables no aporta únicamente valor académico. Si las alertas generadas por estos sistemas pueden justificarse mediante subgrafos interpretables y estables, entonces el proceso de revisión manual se vuelve más eficiente, la priorización de casos mejora y la toma de decisiones se respalda con evidencia estructural más sólida. Esto significa que el beneficio esperado no es solamente una mejora en F1-Score o PR-AUC, sino una reducción del tiempo invertido en examinar alertas irrelevantes y una mayor capacidad para enfocar recursos humanos sobre transacciones verdaderamente sospechosas [7, 13].

1.6.2 Justificación Tecnológica

La pertinencia tecnológica de esta investigación reside en que aborda simultáneamente dos retos que suelen tratarse por separado: la detección estructural de transacciones ilícitas y la confiabilidad de sus explicaciones. Las GNNs son relevantes para AML porque el fenómeno del lavado no se manifiesta únicamente en atributos individuales, sino en configuraciones relacionales que emergen de la red financiera [6, 7]. Sin embargo,

asumir que estas arquitecturas son siempre superiores sería metodológicamente incorrecto. Su ventaja depende del tipo de grafo, de la calidad de las conexiones observadas, de la arquitectura concreta utilizada y de la forma en que se mitigan problemas como el desbalance o el ruido topológico [12, 26].
Por esta razón, la investigación no parte de una defensa dogmática de las GNNs, sino de una evaluación crítica de sus condiciones de utilidad. Del mismo modo, el componente XAI no se incorpora como un complemento estético, sino como una necesidad tecnológica derivada de la opacidad inherente de los modelos profundos. En dominios regulados, una arquitectura altamente precisa pero incapaz de explicar sus decisiones es difícilmente sostenible. En consecuencia, estudiar la estabilidad de explicadores como GNNExplainer, PGExplainer y GNNShap constituye un paso necesario para convertir sistemas prometedores en herramientas realmente auditables [15–17].

1.6.3 Justificación Científica y Social

Desde el punto de vista científico, esta tesis busca aportar evidencia donde hoy existe fragmentación. La literatura ofrece estudios sobre clasificación AML, estudios sobre explicabilidad en grafos y estudios sobre estabilidad XAI en otros dominios, pero aún carece de un marco comparativo que cruce estas dimensiones en un mismo diseño experimental [18, 23, 24]. Al llenar ese vacío, la investigación contribuye a una comprensión más rigurosa sobre cuándo una explicación puede considerarse no solo informativa, sino también estable y operacionalmente confiable.
En el plano social, el problema es igualmente relevante. El lavado de activos permite sostener economías criminales que afectan de forma directa la seguridad, la integridad institucional y la confianza pública. Mejorar la capacidad de detección de flujos ilícitos en criptomonedas tiene implicaciones que trascienden la eficiencia técnica: significa fortalecer los mecanismos de prevención frente a estructuras criminales que se benefician de la velocidad y opacidad parcial de los ecosistemas digitales [10, 11]. Asimismo, en un entorno donde la regulación demanda sistemas más transparentes y justificables, avanzar hacia modelos auditables implica también una contribución ética y jurídica al uso responsable de la inteligencia artificial en finanzas [1].

1.7 Alcance y Limitaciones

El diseño experimental de este estudio se delimita al uso del *Elliptic Dataset*, ampliamente reconocido en la literatura como uno de los referentes más importantes para la detección de actividad ilícita en transacciones de Bitcoin [6, 7]. Sobre este conjunto de datos se construyen escenarios controlados de desbalance mediante estrategias de submuestreo y reconfiguración experimental, con el fin de simular proporciones progresivamente más extremas entre clases. El análisis abarca la comparación de múltiples arquitecturas GNN (GCN, GraphSAGE, GAT, TAGCN), la aplicación de distintos métodos XAI (GNNExplainer, PGExplainer, GNNShap) y la evaluación de estrategias de mitigación del desbalance (ponderación de clases, *focal loss*), todo ello bajo métricas que consideren tanto el rendimiento predictivo como la estabilidad explicativa.
La investigación no contempla el despliegue de un sistema productivo en tiempo real ni la integración directa con infraestructuras bancarias o nodos operativos de redes *blockchain*. Tampoco incluye evaluaciones legales exhaustivas por jurisdicción, estudios de usabilidad con usuarios finales o análisis centrados en otras familias de modelos no basados en

grafos, salvo como referencia teórica. Del mismo modo, no se pretende cubrir todos los explicadores existentes para GNNs, sino concentrarse en un conjunto representativo y metodológicamente justificable de métodos comparables [20, 22]. Esta delimitación es necesaria para preservar profundidad analítica, consistencia experimental y viabilidad metodológica.

1.8 Estructura de la Tesis

Con el propósito de desarrollar de manera coherente la argumentación y responder progresivamente al problema de investigación, la tesis se organiza en siete capítulos interrelacionados.

- El **Capítulo 1** introduce el contexto general de la tesis, presentando el problema de investigación, la revisión del estado del arte, la brecha identificada, la formulación del problema, los objetivos, la justificación y el alcance del estudio.
- El **Capítulo 2** desarrolla el marco contextual desde una perspectiva financiera y regulatoria, abordando el fenómeno del lavado de dinero, las tipologías en criptomonedas, los sistemas tradicionales de monitoreo y sus limitaciones, sin considerar aún enfoques de aprendizaje automático o profundo.
- El **Capítulo 3** presenta los fundamentos técnicos de inteligencia artificial para detección de fraude financiero, incluyendo la transición de ML tabular a GNNs, las arquitecturas evaluadas (GCN, GraphSAGE, GAT, TAGCN), los métodos XAI (GNNExplainer, PGExplainer, GNNShap), las estrategias de mitigación del desbalance y la formalización de las métricas de evaluación.
- El **Capítulo 4** describe el diseño experimental y presenta los resultados obtenidos, incluyendo el análisis exploratorio de datos, el pipeline de experimentación, los escenarios de desbalance evaluados y las mediciones de rendimiento predictivo y estabilidad explicativa.
- El **Capítulo 5** desarrolla la discusión y el análisis crítico de los resultados, vinculándolos con el estado del arte y examinando sus implicaciones desde una perspectiva técnica y operativa.
- El **Capítulo 6** expone las conclusiones de la tesis, sintetizando los principales aportes, las respuestas a los objetivos planteados y las limitaciones identificadas durante la investigación.
- El **Capítulo 7** presenta las perspectivas futuras y los posibles lineamientos de trabajo posterior, junto con los anexos que contienen material complementario relevante para la reproducibilidad del estudio.

Capítulo 2

MARCO CONTEXTUAL

El presente capítulo desarrolla las bases conceptuales y contextuales necesarias para comprender el fenómeno del lavado de dinero desde una perspectiva financiera, regulatoria y operativa, sin abordar aún los fundamentos técnicos de aprendizaje automático o profundo. Su propósito es establecer la magnitud del problema, el andamiaje normativo que lo rodea, las limitaciones de los sistemas de detección convencionales y las particularidades que las criptomonedas introducen en las tipologías de lavado. Este marco permite situar adecuadamente la motivación técnica de la tesis —la detección mediante modelos basados en grafos y su explicabilidad— dentro del contexto real en el que estos sistemas deben operar.

2.1 El Lavado de Dinero como Fenómeno Financiero Global

2.1.1 Definición y naturaleza del lavado de activos

El lavado de dinero, denominado en el ámbito internacional como *money laundering* (ML), es el proceso mediante el cual fondos obtenidos a través de actividades ilícitas —narcotráfico, corrupción, trata de personas, tráfico de armas, evasión fiscal, entre otras— son introducidos en el sistema financiero formal con la apariencia de recursos legítimos [2, 5]. Este fenómeno constituye una amenaza de carácter transversal: no solo sustenta las economías criminales que generan los fondos de origen, sino que además erosiona la integridad de las instituciones financieras, distorsiona los mercados, reduce la confianza en los mecanismos de supervisión y debilita la gobernanza económica de los Estados [3]. La magnitud del lavado de activos a nivel global es difícil de cuantificar con precisión, pero las estimaciones más citadas, provenientes de la Oficina de las Naciones Unidas contra la Droga y el Delito (UNODC), sitúan el volumen de fondos lavados anualmente entre el 2 % y el 5 % del Producto Interno Bruto mundial [27]. En términos absolutos, esto equivale a una cifra que oscila entre 800.000 millones y 2 billones de dólares estadounidenses por año. Para 2024, considerando el crecimiento del PIB global, se estima que el rango podría haber alcanzado entre 2,22 y 5,54 billones de dólares. Estas cifras subrayan que el lavado de activos no es un fenómeno residual ni marginal, sino una fuerza económica de escala sistémica que compite en magnitud con los presupuestos de defensa de naciones enteras. Un dato particularmente alarmante es que, según estimaciones del Banco Mundial, solo alrededor del 1 % de los reportes de transacciones sospechosas generados a nivel global

son efectivamente investigados. Esto refleja una brecha significativa entre la capacidad de generación de alertas y la capacidad institucional de procesarlas, un problema que se abordará con mayor detalle en las secciones dedicadas a los sistemas de monitoreo de transacciones (Sección 2.3).

2.1.2 Las tres etapas del lavado de dinero

La literatura financiera y criminológica coincide en que el lavado de activos se estructura típicamente en tres etapas secuenciales, aunque en la práctica estas fases pueden superponerse, repetirse o adaptarse según el contexto operativo del esquema criminal [28].
La primera etapa corresponde a la colocación (*placement*), en la que los fondos ilícitos son introducidos por primera vez en el sistema financiero. Esta fase es considerada la más vulnerable a la detección, ya que involucra el manejo directo de efectivo o activos de origen criminal. Las técnicas de colocación incluyen el fraccionamiento de depósitos en montos inferiores a los umbrales de reporte (*structuring* o *smurfing*), la compra de instrumentos financieros con efectivo, la utilización de negocios intensivos en efectivo como fachada y, en el contexto digital, la adquisición de criptomonedas en *exchanges* con controles débiles de verificación de identidad.
La segunda etapa es la estratificación (*layering*). Una vez introducidos los fondos en el sistema, esta fase busca separar el dinero de su origen ilícito mediante una serie de transacciones financieras complejas diseñadas para dificultar la trazabilidad. La estratificación puede involucrar transferencias electrónicas entre múltiples cuentas bancarias en diferentes jurisdicciones, la compra y venta sucesiva de activos financieros, el uso de empresas de fachada (*shell companies*) y la conversión entre diferentes tipos de instrumentos. En el contexto de las criptomonedas, esta etapa se ha sofisticado considerablemente mediante el uso de *mixers*, *peel chains* y puentes entre cadenas de bloques, técnicas que se analizarán en detalle en la Sección 2.5. La estratificación es considerada la fase más compleja del proceso de lavado, y es donde los mecanismos de detección enfrentan los mayores desafíos operativos.
La tercera fase es la integración (*integration*), que cierra el ciclo de lavado reintroduciendo los fondos ya estratificados en la economía formal como recursos aparentemente legítimos. En esta etapa, los criminales pueden adquirir bienes inmuebles, invertir en negocios legítimos, comprar activos de lujo o realizar inversiones financieras convencionales. La integración es particularmente difícil de detectar, ya que los fondos han sido procesados a través de múltiples capas de transacciones y su origen criminal se encuentra sustancialmente disimulado.

2.2 Marco Regulatorio Internacional Anti-Lavado de Activos

2.2.1 El Grupo de Acción Financiera Internacional (GAFI/FATF)

El Grupo de Acción Financiera Internacional (GAFI), conocido en inglés como *Financial Action Task Force* (FATF), constituye la máxima autoridad intergubernamental a nivel mundial en la lucha contra el lavado de activos y el financiamiento del terrorismo. Fundado en 1989 por el G-7, el GAFI está conformado actualmente por 39 países miembros y ha

Figura 2.1: Diagrama de flujo que ilustra las tres etapas clásicas del lavado de dinero: colocación, estratificación e integración.

establecido los estándares globales que rigen las políticas de prevención y detección de lavado de activos en todo el mundo [28].
El instrumento normativo central del GAFI son las 40 Recomendaciones, un conjunto de medidas financieras, legales y de conducta que los países deben implementar para establecer sistemas efectivos de detección, prevención y represión del lavado de activos y el financiamiento del terrorismo (LA/FT). Estas recomendaciones incluyen disposiciones sobre evaluación de riesgos, cooperación nacional, tipificación del delito, medidas de decomiso, debida diligencia del cliente (*Customer Due Diligence*, CDD), registro y reporte de operaciones sospechosas, y cooperación internacional. La relevancia de estas recomendaciones para la presente investigación radica en que establecen el marco normativo que exige a las instituciones financieras disponer de sistemas de monitoreo capaces de identificar, reportar y justificar las alertas de actividad sospechosa.

2.2.2 Regulación de activos virtuales y la Regla de Viaje

Con el crecimiento exponencial de las criptomonedas y los activos virtuales, el GAFI ha actualizado sus directrices para incluir a los Proveedores de Servicios de Activos Virtuales (*Virtual Asset Service Providers*, VASPs) bajo el mismo marco regulatorio que las instituciones financieras tradicionales. Esta extensión normativa reconoce que los activos virtuales presentan riesgos similares —y en algunos casos superiores— a los instrumentos financieros tradicionales en términos de potencial para el lavado de activos. Un componente clave de esta regulación es la denominada Regla de Viaje (*Travel Rule*), que exige a los VASPs recopilar y transmitir datos personales tanto del emisor como del receptor para transferencias que superen los 1.000 dólares o euros. Esta disposición busca replicar en el ecosistema cripto los controles de transparencia que ya existen en las transferencias bancarias internacionales, aunque su implementación efectiva sigue siendo un desafío debido a la naturaleza descentralizada de muchas plataformas.

2.2.3 Enfoque de Gestión de Riesgos del Comité de Basilea

A nivel de supervisión bancaria prudencial, el Comité de Basilea para la Supervisión Bancaria (*Basel Committee on Banking Supervision*) emitió directrices sobre la gestión sólida de riesgos relacionados con el lavado de dinero y el financiamiento del terrorismo [29]. Estas directrices establecen que los bancos deben implementar políticas y procesos robustos para mantener altos estándares éticos y prevenir el uso indebido de sus servicios para actividades criminales. El enfoque basado en riesgos que promueve el Comité de Basilea es particularmente relevante para esta investigación, ya que implica que los sistemas de detección deben ser capaces no solo de identificar transacciones sospechosas, sino también de priorizar y justificar las alertas generadas en función de su nivel de riesgo.

2.2.4 Debida Diligencia del Cliente (KYC)

En el centro de los marcos regulatorios AML se encuentran los procedimientos de *Know Your Customer* (KYC), que constituyen el componente operativo fundamental para la verificación de identidad de los clientes y la evaluación de sus perfiles de riesgo. Los requisitos de KYC incluyen la Debida Diligencia del Cliente (CDD) y la Debida Diligencia Reforzada (*Enhanced Due Diligence*, EDD) para clientes de alto riesgo, como personas políticamente expuestas (PEPs) o clientes de jurisdicciones de alto riesgo. La efectividad de estos procedimientos depende en gran medida de la capacidad tecnológica de las instituciones para procesar, verificar y monitorear la información recopilada, lo cual conecta directamente con la necesidad de sistemas de monitoreo más sofisticados que los basados en reglas estáticas.

2.3 Sistemas Tradicionales de Monitoreo de Transacciones

2.3.1 Arquitectura de los sistemas basados en reglas

Los Sistemas de Monitoreo de Transacciones (*Transaction Monitoring Systems*, TMS) convencionales constituyen la columna vertebral tecnológica del cumplimiento AML en las instituciones financieras desde hace décadas. Estos sistemas se fundamentan en reglas deterministas, listas de vigilancia y umbrales estáticos predefinidos para identificar transacciones potencialmente sospechosas. Su lógica operativa se basa en criterios preestablecidos derivados de patrones conocidos de fraude, tales como cambios súbitos en el volumen de transacciones, ubicaciones geográficas inusuales para compras, o transacciones repetitivas dentro de períodos cortos de tiempo. Aunque este enfoque fue razonable en sus orígenes, su rigidez lo hace inadecuado frente a las tipologías de lavado contemporáneas, que se caracterizan por su capacidad de adaptación y su explotación de patrones relacionales que los sistemas basados en reglas no pueden capturar.

2.3.2 El problema de los falsos positivos

El problema más crítico y ampliamente documentado de los TMS convencionales es su extraordinaria tasa de falsos positivos. Según informes de la industria, entre el 90 % y el 98 % de todas las alertas generadas por los sistemas de monitoreo de transacciones corresponden a falsos positivos [30]. Esto significa que la abrumadora mayoría de las

alertas generadas por estos sistemas no corresponden a actividades genuinamente sospechosas, sino a transacciones legítimas que coincidieron con algún patrón predefinido.
Las consecuencias operativas de esta tasa son profundas. La carga real puede ascender hasta 22 horas por alerta cuando se consideran los procesos completos de investigación y documentación. Esta sobrecarga genera fatiga organizacional en los equipos de cumplimiento, quienes deben dedicar la mayor parte de su tiempo a perseguir señales falsas en lugar de concentrarse en amenazas genuinas. La paradoja resultante es evidente: un sistema diseñado para detectar actividad ilícita termina consumiendo la mayor parte de sus recursos en actividad que resulta ser legítima.

2.3.3 Costos del cumplimiento AML

La ineficiencia de los sistemas de monitoreo se traduce directamente en costos económicos desproporcionados. El informe anual *True Cost of Financial Crime Compliance* de 2023 revela que las instituciones financieras a nivel global soportan un costo total de 206.100 millones de dólares por el cumplimiento de delitos financieros [30]. Esta cifra abarca no solo la infraestructura tecnológica, sino también los recursos humanos dedicados a la investigación de alertas, la capacitación regulatoria y los procesos de auditoría interna.
Estas cifras ilustran una paradoja fundamental: a pesar de la inversión masiva en sistemas de cumplimiento, el volumen de lavado de activos a nivel global no muestra señales claras de disminución. Como observa Kelkar (2024), los flujos financieros ilícitos continúan representando una amenaza significativa para la estabilidad económica internacional [1]. Esta desproporción entre inversión y resultados subraya la necesidad de un cambio de paradigma en la forma en que se abordan la detección y el monitoreo de actividades sospechosas.

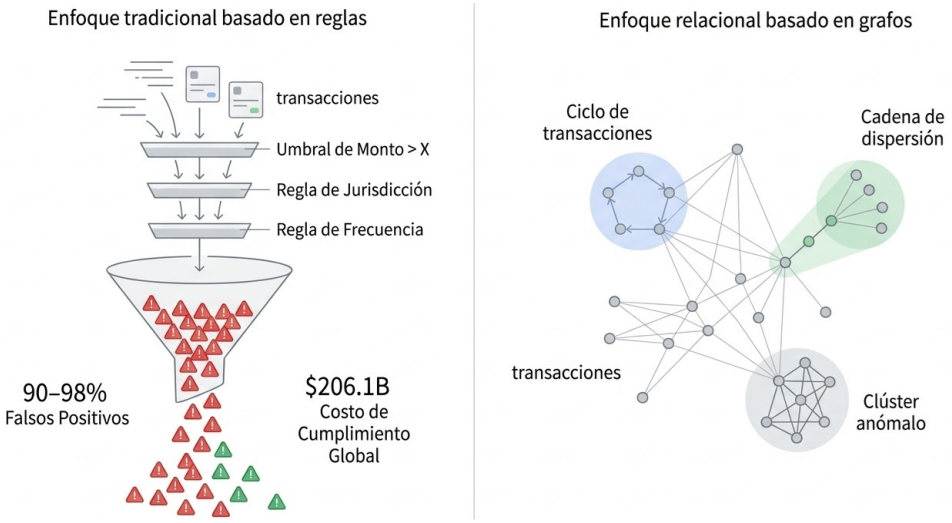

Figura 2.2: Comparación entre monitoreo transaccional basado en reglas, con umbrales estáticos y hasta 90–98% de falsos positivos, y un enfoque relacional basado en grafos, donde las transacciones se analizan como redes para detectar patrones estructurales sospechosos.

2.4 Criptomonedas y Delincuencia Financiera

2.4.1 Seudonimato y arquitectura descentralizada

La emergencia de las criptomonedas ha transformado radicalmente el panorama del lavado de activos al introducir un medio de transferencia de valor que opera fuera de la infraestructura financiera tradicional [2]. Es importante realizar una distinción conceptual entre anonimato y seudonimato. Las criptomonedas como Bitcoin no proporcionan anonimato completo, sino seudonimato: cada transacción queda registrada de forma inmutable en la cadena de bloques y es públicamente verificable, pero las direcciones involucradas no están directamente vinculadas a identidades del mundo real [3]. Esta propiedad es simultáneamente una oportunidad y un desafío para los mecanismos de detección, puesto que la disponibilidad pública de los datos transaccionales permite aplicar técnicas de análisis de redes, pero la dificultad para vincular direcciones con identidades limita la capacidad de atribución directa.

2.4.2 Magnitud de la actividad ilícita en criptomonedas

Los datos más recientes revelan la magnitud creciente de la actividad criminal en el ecosistema cripto. Según reportes de la industria, en 2025 el volumen ilícito en criptomonedas alcanzó los 154.000 millones de dólares, un aumento sustancial respecto a años anteriores [31]. Como señala Europol en su informe EU-SOCTA 2025, la explotación criminal de las criptomonedas ha trascendido el ámbito del cibercrimen para permear áreas delictivas más tradicionales como el narcotráfico y el tráfico de personas [32]. Estas cifras confirman que el ecosistema de criptomonedas se ha convertido en un componente estructural del panorama financiero ilícito global, y no en un fenómeno marginal o transitorio.

2.5 Tipologías de Lavado de Dinero en Criptomonedas

2.5.1 Mezcladores y servicios de ofuscación

Los *mixers* o *tumblers* de criptomonedas representan una de las herramientas más utilizadas para la estratificación de fondos ilícitos. Funcionan como contratos inteligentes o servicios centralizados que reciben criptomonedas de múltiples usuarios, las combinan en un fondo común, y luego redistribuyen cantidades equivalentes a los participantes, rompiendo así el vínculo rastreable entre las direcciones de origen y destino. La efectividad de los mezcladores reside en que, al combinar fondos de múltiples fuentes, crean una capa de ambigüedad que dificulta significativamente el rastreo forense de los flujos individuales.

2.5.2 Cadenas de pelado (*Peel Chains*)

Las *peel chains* constituyen una técnica de lavado en la que una dirección con una cantidad significativa de criptomonedas realiza transacciones sucesivas, “pelando” cantidades cada vez más pequeñas hacia diferentes direcciones en cada paso. Esto distribuye los fondos gradualmente a través de una cadena de direcciones intermedias, creando una estructura transaccional larga y ramificada que complica significativamente el rastreo. Esta tipología resulta particularmente relevante para el contexto de esta tesis, ya que las *peel chains*

generan patrones topológicos característicos en el grafo de transacciones que las GNNs podrían identificar mediante la agregación de información de vecindarios extendidos.

2.5.3 Saltos de cadena y puentes entre *blockchains*

El *chain hopping* o salto de cadena implica la conversión rápida y sucesiva de una criptomoneda a otra, generalmente utilizando diferentes *blockchains*, con el propósito de dificultar el seguimiento de los fondos. Los puentes entre cadenas (*cross-chain bridges*) son las herramientas tecnológicas que facilitan estas transferencias interoperables. La complejidad de detección que introduce esta técnica es considerable, ya que los analistas deben rastrear los flujos no solo dentro de una cadena de bloques, sino a través de múltiples ecosistemas con diferentes protocolos, formatos de datos y niveles de transparencia.

2.5.4 Otras técnicas de lavado en criptomonedas

Además de las técnicas principales, el ecosistema cripto ha desarrollado un repertorio diverso de mecanismos complementarios. El *smurfing* consiste en fragmentar grandes cantidades en múltiples transacciones pequeñas que quedan por debajo de los umbrales de reporte. Los *exchanges* descentralizados (DEX) permiten intercambios directos entre pares sin intermediario centralizado, eliminando un punto natural de control y vigilancia. Las *privacy coins* como Monero incorporan protocolos criptográficos que ofrecen un anonimato estructural superior al del Bitcoin, haciendo que el rastreo de transacciones sea técnicamente inviable en muchos casos. Almeida et al. (2025) documentan cómo estas estrategias de dispersión y transacciones encadenadas aprovechan la estructura de red de los ecosistemas digitales [4].

2.5.5 Comparación de técnicas de lavado

La Tabla 2.1 sintetiza las principales técnicas de lavado de dinero empleadas en el ecosistema de criptomonedas, clasificándolas según la etapa predominante del proceso de lavado, el mecanismo operativo y la complejidad que representan para los sistemas de detección.

2.6 Desafíos de la Detección de Fraude Financiero en el Ecosistema Cripto

2.6.1 Desafíos operativos y regulatorios

La detección de lavado de dinero en criptomonedas enfrenta un conjunto interrelacionado de desafíos que trascienden las capacidades de los sistemas convencionales. En primer lugar, el seudonimato inherente a las criptomonedas dificulta la identificación de las partes involucradas, ya que las direcciones de billeteras no están vinculadas de forma directa a identidades verificadas. En segundo lugar, la naturaleza transfronteriza de las transacciones genera desafíos jurisdiccionales significativos, puesto que una misma operación puede involucrar actores en múltiples países con marcos regulatorios diferentes o incompatibles. En tercer lugar, la velocidad de las transacciones en el ecosistema cripto supera ampliamente la capacidad de respuesta de los mecanismos tradicionales

Técnica	**Etapa predominante**	**Mecanismo**	**Complejidad de detección**
Smurfing / Estructuración	Colocación	Fraccionamiento de transacciones bajo umbrales de reporte	Media
Mixers / *Tumblers*	Estratificación	Combinación de fondos de múltiples usuarios para romper trazabilidad	Alta
Peel Chains	Estratificación	Transferencias sucesivas de montos decrecientes a múltiples direcciones	Alta
Chain Hopping	Estratificación	Conversión rápida entre diferentes *blockchains*	Muy alta
Cross-chain Bridges	Estratificación	Puentes tecnológicos para transferir valor entre *blockchains* distintas	Muy alta
Trading en DEX	Estratificación	Intercambio directo P2P sin intermediario centralizado	Alta
Privacy Coins	Estrat./Integ.	Protocolos criptográficos que anonimizan transacciones por diseño	Muy alta
Compra de activos	Integración	Adquisición de bienes inmuebles o de lujo con cripto convertido	Baja–Media

Cuadro 2.1: Principales técnicas de lavado de dinero en criptomonedas, clasificadas por etapa, mecanismo y complejidad de detección.

de monitoreo [3]. Estos tres factores combinados crean un entorno en el que las técnicas convencionales de detección resultan estructuralmente insuficientes.

2.6.2 La brecha entre regulación y realidad operativa

Existe una tensión inherente entre el ritmo de innovación en el ecosistema cripto y la capacidad de los marcos regulatorios para adaptarse. Mientras que nuevas técnicas de lavado, plataformas descentralizadas y mecanismos de ofuscación surgen continuamente, los marcos normativos requieren procesos deliberativos extensos para su actualización. Este desfase genera ventanas de oportunidad que los actores ilícitos explotan de manera sistemática. El contexto regulatorio fragmentado es particularmente relevante para la presente tesis, ya que subraya la necesidad de desarrollar herramientas de detección que puedan operar de forma efectiva basándose en los patrones estructurales y relacionales que las transacciones exhiben dentro de la red, independientemente de la capacidad de las regulaciones para mantener el ritmo de la innovación criminal.

2.7 Del Monitoreo Basado en Reglas hacia Enfoques Estructurales

2.7.1 Limitaciones fundamentales del enfoque tabular

La limitación estructural común a los sistemas tradicionales de detección AML es su tratamiento de las transacciones como eventos aislados e independientes. Los TMS convencionales analizan cada transacción en función de sus atributos individuales —monto, frecuencia, geolocalización, temporalidad— sin considerar las relaciones topológicas entre las entidades involucradas. Como se ha mostrado a lo largo de este capítulo, las tipologías contemporáneas de lavado en criptomonedas se caracterizan precisamente por explotar patrones relacionales que solo son visibles cuando se analiza la estructura de la red transaccional en su conjunto.

2.7.2 Transacciones financieras como grafos

La representación de redes transaccionales como grafos ofrece un marco conceptual natural para abordar las limitaciones del enfoque tabular. En este paradigma, las entidades financieras se representan como nodos del grafo, mientras que las transacciones entre ellas constituyen las aristas. Esta formulación permite capturar propiedades fundamentales de las redes financieras que son invisibles para los modelos tabulares, tales como la centralidad de determinados nodos, la existencia de comunidades densamente conectadas, la presencia de cadenas de transacciones sospechosamente largas o la formación de ciclos que sugieren mecanismos de estratificación.

2.7.3 El Elliptic Dataset como referente

En el contexto específico de la detección AML en Bitcoin, el *Elliptic Dataset* se ha consolidado como uno de los conjuntos de datos de referencia más importantes. Este dataset contiene 203.769 nodos (transacciones de Bitcoin) conectados por 234.355 aristas, donde cada nodo posee 166 características y una etiqueta forense verificada (lícita, ilícita o desconocida). El trabajo pionero de Weber et al. (2019) demostró que la representación de la red de transacciones Bitcoin como un grafo permite capturar patrones estructurales que los modelos tabulares no pueden identificar [6]. Unagar y Borisaniya (2025) confirman que los métodos basados en grafos representan el estado más avanzado de la técnica para este dominio [5]. La elección del *Elliptic Dataset* como base experimental de esta tesis se fundamenta en su consolidación como estándar de la comunidad científica y en la disponibilidad de etiquetas verificadas que permiten una evaluación rigurosa.

2.7.4 Hacia la necesidad de modelos explicables

En un entorno donde las decisiones automatizadas pueden derivar en el bloqueo de cuentas o investigaciones con implicaciones jurídicas significativas, la capacidad de explicar y justificar las alertas generadas es tan importante como su precisión predictiva. Los marcos regulatorios analizados en este capítulo —desde las 40 Recomendaciones del GAFI hasta las directrices del Comité de Basilea— exigen que las instituciones financieras puedan demostrar la razonabilidad de sus decisiones de monitoreo. Esto implica que los modelos de detección deben producir no solo una clasificación binaria, sino también una justificación comprensible del porqué. Este requisito conecta directamente con el objeto central de la

presente tesis: la evaluación de la estabilidad de los métodos de explicabilidad (XAI) aplicados a modelos de grafos para detección AML, que se desarrollará a partir del Capítulo 3.

Capítulo 3

FUNDAMENTOS DE IA PARA DETECCIÓN DE FRAUDE FINANCIERO

El presente capítulo introduce los fundamentos técnicos del Aprendizaje Automático (*Machine Learning*, ML) y el Aprendizaje Profundo (*Deep Learning*, DL) aplicados al dominio de detección de fraude financiero. La exposición se organiza como una progresión conceptual que parte de los paradigmas tabulares clásicos, transita hacia las *Graph Neural Networks* (GNNs) como respuesta a las limitaciones estructurales de dichos paradigmas, y culmina con la presentación de los métodos de explicabilidad (XAI) y las estrategias de mitigación del desbalance de clases. El propósito de este recorrido es dotar al lector de las bases teóricas y matemáticas necesarias para comprender el diseño experimental que se desarrollará en el Capítulo 4.

3.1 Del Aprendizaje Automático al Aprendizaje Profundo

3.1.1 Aprendizaje Automático: Definición y Paradigmas

El Aprendizaje Automático constituye un subcampo de la inteligencia artificial orientado al desarrollo de algoritmos capaces de aprender patrones a partir de datos sin ser explícitamente programados para cada tarea específica. En el contexto de detección de fraude financiero, los enfoques de ML han evolucionado desde sistemas basados en reglas deterministas hacia modelos estadísticos que identifican comportamientos anómalos mediante el análisis de características transaccionales.

Los paradigmas fundamentales del ML se clasifican en tres categorías principales. El aprendizaje supervisado entrena modelos a partir de datos etiquetados, donde cada instancia está asociada con una categoría conocida (por ejemplo, “lícita” o “ilícita”); este paradigma es central para la detección AML, donde se busca clasificar transacciones en función de ejemplos históricos verificados, y sus algoritmos clásicos incluyen regresión logística, árboles de decisión, *Random Forest* y *Support Vector Machines* [5]. El aprendizaje no supervisado identifica estructuras ocultas en datos no etiquetados, siendo particularmente útil para la detección de anomalías cuando no se dispone de suficientes ejemplos etiquetados de fraude; técnicas como *clustering* y reducción de dimensionalidad han sido empleadas para identificar patrones transaccionales atípicos. El aprendizaje semi-supervisado combina un pequeño conjunto de datos etiquetados con una gran cantidad de datos sin etiquetar,

aprovechando la estructura subyacente de los datos para mejorar el rendimiento del modelo; este paradigma es especialmente relevante en AML, donde las etiquetas verificadas son costosas de obtener debido a la necesidad de investigación manual [7].

3.1.2 Limitaciones del ML Tabular en Detección AML

Los métodos tradicionales de ML tratan las transacciones financieras como instancias independientes, representadas mediante vectores de características numéricas extraídas de cada transacción individual: monto, frecuencia, geolocalización, temporalidad, entre otras. Aunque estos enfoques han demostrado capacidad para identificar patrones conocidos de fraude, enfrentan limitaciones estructurales en escenarios contemporáneos de lavado de activos [5].

La primera limitación radica en su incapacidad para capturar dependencias relacionales. El lavado de dinero no se manifiesta únicamente en las características de una transacción aislada, sino en patrones topológicos que emergen de múltiples transacciones interconectadas: cadenas de dispersión, ciclos transaccionales, estructuras de intermediación artificial y vecindarios sospechosos [6, 7]. Los modelos tabulares, al ignorar estas dependencias, pierden información crítica sobre la estructura de la red financiera.

La segunda limitación es la ingeniería de características manual. Los enfoques clásicos requieren que expertos del dominio diseñen características agregadas que intenten capturar información relacional de forma indirecta (por ejemplo, número de conexiones, promedios de montos de vecinos). Este proceso es laborioso, dependiente del conocimiento experto y potencialmente incompleto frente a tipologías de fraude emergentes [5].

La tercera limitación concierne a la escalabilidad. A medida que las redes transaccionales crecen en tamaño y complejidad, la construcción manual de características relacionales se vuelve computacionalmente intratable. Este problema es particularmente agudo en ecosistemas de criptomonedas, donde la velocidad y el volumen de transacciones superan ampliamente los flujos financieros tradicionales.

3.1.3 El Aprendizaje Profundo como Paradigma de Representación

El Aprendizaje Profundo representa una evolución del ML caracterizada por el uso de arquitecturas neuronales con múltiples capas de procesamiento que aprenden representaciones jerárquicas de los datos de forma automática. A diferencia de los métodos tradicionales que requieren ingeniería manual de características, los modelos de DL son capaces de descubrir automáticamente representaciones útiles directamente desde los datos crudos [5, 13].

Las redes neuronales profundas han demostrado capacidad excepcional para modelar funciones complejas no lineales en dominios diversos: visión computacional, procesamiento de lenguaje natural, reconocimiento de voz y, más recientemente, análisis de grafos. Su arquitectura multicapa permite que las capas iniciales capturen características de bajo nivel (patrones simples), mientras que capas superiores construyen representaciones abstractas de alto nivel mediante composición jerárquica.

En el contexto de detección AML, el DL ofrece dos ventajas fundamentales: primero, la capacidad de aprender automáticamente características discriminativas desde datos transaccionales sin requerir conocimiento experto previo; segundo, la flexibilidad arquitectónica para incorporar diferentes tipos de datos (atributos numéricos, secuencias temporales, estructuras de grafos) dentro de un marco unificado [13].

No obstante, esta potencia representacional introduce un desafío crítico: la opacidad. Los modelos de DL operan como "cajas negras" cuyo proceso interno de decisión es difícil de interpretar, generando una tensión entre desempeño predictivo y auditabilidad en dominios regulados como AML [18]. Esta tensión motiva la necesidad de métodos de explicabilidad que se abordarán en la Sección 3.4.

3.2 Graph Neural Networks: Fundamentos Conceptuales

3.2.1 Representación de Datos Financieros como Grafos

Un grafo $G = (V, E)$ consiste en un conjunto de nodos (vértices) V y un conjunto de aristas (conexiones) E que conectan pares de nodos. En el dominio de transacciones financieras, esta representación es naturalmente adecuada: cada entidad (cuenta bancaria, billetera de criptomonedas, usuario) se modela como un nodo, mientras que cada transacción entre dos entidades constituye una arista dirigida que conecta el nodo origen con el nodo destino [6, 7].

Formalmente, sea $G = (V, E, \mathbf{X}, \mathbf{y})$ un grafo donde $V = \{v_1, v_2, \ldots, v_N\}$ representa el conjunto de N nodos (entidades financieras), $E \subseteq V \times V$ representa el conjunto de aristas (transacciones), $\mathbf{X} \in \mathbb{R}^{N \times F}$ es la matriz de características de nodos donde cada fila $\mathbf{x}_i \in \mathbb{R}^F$ contiene F características del nodo v_i, y $\mathbf{y} \in \{0, 1\}^N$ es el vector de etiquetas donde $y_i = 1$ indica actividad ilícita.

En el *Elliptic Dataset*, cada nodo representa una transacción de Bitcoin con 166 características que incluyen estadísticas agregadas del flujo transaccional (número de entradas y salidas, montos totales), características temporales y propiedades topológicas locales. Las aristas conectan transacciones que comparten direcciones Bitcoin, capturando así el flujo de fondos en la red [6, 7]. Esta formulación gráfica permite expresar explícitamente las dependencias relacionales que los modelos tabulares ignoran. Por ejemplo, una transacción puede ser benigna cuando se analiza aisladamente, pero sospechosa cuando se observa su posición dentro de una cadena de dispersión (*peel chain*) o su proximidad a servicios de mezcla conocidos (*mixers*).

3.2.2 El Paradigma de Message Passing

Las *Graph Neural Networks* operan bajo el principio de *message passing* (paso de mensajes), un marco computacional donde cada nodo actualiza iterativamente su representación mediante la agregación de información de sus vecinos en el grafo [12, 13]. El proceso general de una capa GNN se puede descomponer en tres operaciones fundamentales.

La primera operación es la generación de mensajes (*message function*). Para cada nodo v_i, se generan mensajes desde sus vecinos $\mathcal{N}(v_i)$ usando una función parametrizada:

$$m_{ji}^{(k)} = \text{MESSAGE}^{(k)}(\mathbf{h}_j^{(k-1)}, \mathbf{h}_i^{(k-1)}, e_{ji})$$

donde $\mathbf{h}_i^{(k-1)}$ es la representación del nodo i en la capa anterior, $\mathbf{h}_j^{(k-1)}$ es la representación de un vecino j, y e_{ji} representa las características de la arista.

La segunda operación es la agregación de mensajes (*aggregation function*). Los mensajes recibidos se combinan mediante una función de agregación invariante a permutaciones (*permutation-invariant*):

$$\mathbf{m}_i^{(k)} = \text{AGGREGATE}^{(k)}\left(\{m_{ji}^{(k)} : j \in \mathcal{N}(v_i)\}\right)$$

Las funciones comunes de agregación incluyen suma ($\sum$), promedio (mean) y máximo (max), entre otras variantes más complejas.
La tercera operación es la actualización de estado (*update function*). La representación del nodo se actualiza combinando su estado anterior con el mensaje agregado:

$$\mathbf{h}_i^{(k)} = \text{UPDATE}^{(k)}(\mathbf{h}_i^{(k-1)}, \mathbf{m}_i^{(k)})$$

que típicamente se implementa como $\mathbf{h}_i^{(k)} = \sigma(\mathbf{W}^{(k)}[\mathbf{h}_i^{(k-1)} \parallel \mathbf{m}_i^{(k)}])$, donde $\mathbf{W}^{(k)}$ son parámetros aprendibles, $\parallel$ denota concatenación y σ es una función de activación no lineal.
Este proceso se repite por K capas, permitiendo que cada nodo agregue información desde vecindarios cada vez más amplios. Después de K iteraciones, la representación de un nodo captura información estructural hasta una distancia de K saltos en el grafo.

3.2.3 Ventajas de las GNNs en Detección AML

Las GNNs ofrecen tres ventajas fundamentales sobre métodos tradicionales en el contexto AML. En primer lugar, explotan explícitamente la topología del grafo, lo que permite identificar patrones relacionales invisibles para modelos tabulares; por ejemplo, pueden detectar que una transacción forma parte de una cadena de dispersión al analizar el patrón de conectividad de sus vecinos hasta múltiples saltos [6, 7]. En segundo lugar, aprenden automáticamente representaciones óptimas de nodos mediante *backpropagation*, eliminando la necesidad de ingeniería manual de características relacionales; las representaciones aprendidas codifican tanto atributos intrínsecos de los nodos como su posición estructural en la red [12, 13]. En tercer lugar, arquitecturas como GraphSAGE y GAT poseen capacidad inductiva, es decir, pueden generar representaciones para nodos no vistos durante el entrenamiento mediante la aplicación de funciones de agregación aprendidas, una propiedad crítica en redes financieras dinámicas donde continuamente emergen nuevas entidades y transacciones.
Estudios recientes han demostrado la superioridad de las GNNs en detección AML. Lawal et al. mostraron que modelos basados en grafos superan consistentemente a enfoques tabulares en el *Elliptic Dataset* [7], mientras que He et al. confirmaron que las GNNs capturan patrones estructurales complejos que otros métodos pierden [13].

3.3 Arquitecturas GNN Evaluadas

Esta sección presenta las cuatro arquitecturas GNN seleccionadas para el marco comparativo de esta investigación. Cada arquitectura emplea un mecanismo de agregación diferente, lo que permite aislar el efecto de dicho mecanismo sobre la estabilidad explicativa bajo desbalance extremo.

3.3.1 Graph Convolutional Networks (GCN)

Las *Graph Convolutional Networks*, propuestas por Kipf y Welling, constituyen una de las arquitecturas GNN más influyentes. Su diseño simplifica la convolución espectral en grafos mediante una formulación espacial eficiente [6]. La regla de propagación de una capa GCN se define como:

$$\mathbf{H}^{(k+1)} = \sigma(\tilde{\mathbf{D}}^{-1/2}\tilde{\mathbf{A}}\tilde{\mathbf{D}}^{-1/2}\mathbf{H}^{(k)}\mathbf{W}^{(k)})$$

donde $\mathbf{H}^{(k)} \in \mathbb{R}^{N \times F_k}$ es la matriz de representaciones de nodos en la capa k, $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$ es la matriz de adyacencia con *self-loops* agregados, $\tilde{\mathbf{D}}$ es la matriz diagonal de grados correspondiente a $\tilde{\mathbf{A}}$, $\mathbf{W}^{(k)} \in \mathbb{R}^{F_k \times F_{k+1}}$ son parámetros aprendibles y σ es una función de activación no lineal.
Esta formulación realiza un promedio ponderado normalizado de las características de los vecinos, seguido de una transformación lineal y activación no lineal. La normalización simétrica $\tilde{\mathbf{D}}^{-1/2}\tilde{\mathbf{A}}\tilde{\mathbf{D}}^{-1/2}$ estabiliza el entrenamiento al prevenir que nodos con muchos vecinos dominen la agregación. La principal característica de GCN es su agregación isotrópica: todos los vecinos contribuyen por igual, ponderados únicamente por su grado. Si bien esta simplicidad es computacionalmente eficiente, puede resultar subóptima cuando diferentes vecinos tienen relevancia distinta para la tarea de clasificación. Weber et al. demostraron que GCN aplicada al *Elliptic Dataset* supera significativamente a modelos tabulares clásicos, capturando patrones estructurales de lavado de dinero [6].

3.3.2 GraphSAGE: Aprendizaje Inductivo y Muestreo de Vecindarios

GraphSAGE (*Graph Sample and AggregatE*) introduce dos innovaciones fundamentales: capacidad inductiva mediante funciones de agregación aprendidas y escalabilidad mediante muestreo de vecindarios. La actualización de representación en GraphSAGE se formula como:

$$\mathbf{h}_i^{(k)} = \sigma(\mathbf{W}^{(k)} \cdot \mathrm{CONCAT}(\mathbf{h}_i^{(k-1)}, \mathrm{AGG}^{(k)}(\{\mathbf{h}_j^{(k-1)}, \forall j \in \mathcal{N}(v_i)\})))$$

donde la función AGG puede adoptar diferentes formas: promedio (*mean*), máximo (*max*) o agregación basada en LSTM aplicada sobre una permutación aleatoria de los vecinos. Para mantener complejidad computacional constante, GraphSAGE muestrea un número fijo S de vecinos en cada capa, lo que previene la explosión exponencial del árbol de computación y permite entrenamiento por *mini-batches*.
La propiedad más relevante de GraphSAGE para esta investigación es su capacidad inductiva: al aprender funciones de agregación generalizables, puede generar representaciones para nodos nunca vistos durante el entrenamiento. Esta propiedad es crítica en redes transaccionales dinámicas donde continuamente emergen nuevas entidades. Además, la flexibilidad en la elección del agregador permite capturar diferentes aspectos de los patrones relacionales presentes en la red financiera.

3.3.3 Graph Attention Networks (GAT)

Las *Graph Attention Networks* incorporan mecanismos de atención que permiten asignar pesos aprendibles a diferentes vecinos, superando la limitación isotrópica de GCN. El mecanismo de atención en GAT se define como:

$$\alpha_{ij} = \frac{\exp(\mathrm{LeakyReLU}(\mathbf{a}^T[\mathbf{W}\mathbf{h}_i \,\|\, \mathbf{W}\mathbf{h}_j]))}{\sum_{k \in \mathcal{N}(v_i)} \exp(\mathrm{LeakyReLU}(\mathbf{a}^T[\mathbf{W}\mathbf{h}_i \,\|\, \mathbf{W}\mathbf{h}_k]))}$$

Los coeficientes de atención α_{ij} determinan la importancia del vecino j para el nodo i, y la actualización de representación es entonces:

$$\mathbf{h}_i^{(k)} = \sigma\left(\sum_{j \in \mathcal{N}(v_i)} \alpha_{ij}^{(k)} \mathbf{W}^{(k)} \mathbf{h}_j^{(k-1)}\right)$$

GAT emplea múltiples cabezas de atención en paralelo (*multi-head attention*), concatenando o promediando sus salidas para estabilizar el aprendizaje y capturar diferentes aspectos relacionales. La agregación anisotrópica que resulta de este mecanismo es teóricamente superior a la de GCN en tareas donde la importancia de los vecinos varía, aunque conlleva un costo computacional mayor debido al cálculo de atención por arista. Un aspecto relevante para esta investigación es que los coeficientes de atención pueden inspeccionarse, ofreciendo una forma parcial de interpretabilidad intrínseca que complementa los métodos XAI post-hoc [11].

3.3.4 TAGCN: Convolución Adaptativa por Topología

La *Topology Adaptive Graph Convolutional Network* (TAGCN) constituye una extensión de las GNNs convencionales que incorpora filtros polinomiales adaptativos para capturar dependencias estructurales de mayor alcance [12]. A diferencia de GCN, que emplea una aproximación de primer orden limitada al vecindario inmediato, TAGCN define filtros que pueden agregar información desde múltiples saltos topológicos mediante polinomios de Chebyshev.
La formulación de TAGCN se basa en la teoría de procesamiento de señales en grafos (*Graph Signal Processing*, GSP), donde las convoluciones espectrales en grafos se expresan como filtros polinomiales sobre la matriz de adyacencia normalizada:

$$g_\theta(\mathbf{L}) = \sum_{k=0}^{K-1} \theta_k \mathbf{T}_k(\tilde{\mathbf{L}})$$

donde $\mathbf{L}$ es el Laplaciano normalizado del grafo, $\tilde{\mathbf{L}} = 2\mathbf{L}/\lambda_{\max} - \mathbf{I}$ es el Laplaciano reescalado al intervalo $[-1, 1]$, $\mathbf{T}_k$ son polinomios de Chebyshev de orden k, y θ_k son parámetros aprendibles. La recursión de Chebyshev permite computar eficientemente los polinomios sin calcular la descomposición espectral completa del grafo:

$$\mathbf{T}_0(\mathbf{x}) = 1, \quad \mathbf{T}_1(\mathbf{x}) = \mathbf{x}, \quad \mathbf{T}_k(\mathbf{x}) = 2\mathbf{x}\mathbf{T}_{k-1}(\mathbf{x}) - \mathbf{T}_{k-2}(\mathbf{x})$$

En la práctica, TAGCN utiliza $K = 3$, lo que permite capturar dependencias hasta 2 saltos en el grafo manteniendo una complejidad computacional lineal en el número de aristas [12]. Esta capacidad *multi-hop* resulta particularmente relevante para el dominio AML, donde las tipologías de lavado analizadas en el Capítulo 2 —*peel chains*, *chain hopping*, cadenas de dispersión— involucran patrones estructurales que se extienden más allá del vecindario inmediato. Du et al. demostraron que TAGCN alcanza resultados competitivos en múltiples *benchmarks* de clasificación de nodos, lo que motivó su inclusión en el marco comparativo de esta investigación [12]. Adicionalmente, su fundamentación teórica en procesamiento de señales en grafos proporciona garantías sobre propiedades deseables como invariancia a permutaciones y consistencia con definiciones clásicas de convolución.

3.3.5 Síntesis Comparativa de Arquitecturas

La selección de estas cuatro arquitecturas no es arbitraria, sino que responde a la necesidad de cubrir un espectro representativo de mecanismos de agregación. GCN representa la agregación isotrópica más simple. GraphSAGE introduce la capacidad inductiva y la flexibilidad en la función de agregación. GAT incorpora atención anisotrópica aprendida. TAGCN añade filtros polinomiales adaptativos capaces de operar sobre múltiples saltos

topológicos. Esta diversidad permite que el diseño experimental del Capítulo 4 aísle el efecto del mecanismo de agregación sobre la estabilidad de las explicaciones, una dimensión que la literatura aún no ha explorado de manera sistemática.
Los hiperparámetros específicos de cada arquitectura (número de capas, dimensiones ocultas, tasas de *dropout*, funciones de activación y esquemas de optimización) se detallarán en el Capítulo 4, junto con el proceso de optimización mediante Optuna que se empleó para determinar las configuraciones más adecuadas para cada combinación de arquitectura y escenario de desbalance.

3.4 El Desafío de la Explicabilidad en GNNs

3.4.1 Necesidad de Interpretabilidad en Contextos Regulados

Las *Graph Neural Networks*, a pesar de su potencia predictiva, operan como modelos altamente opacos cuyo proceso interno de decisión resulta difícil de interpretar para analistas humanos. En dominios como la detección AML, esta opacidad genera tensiones críticas con requisitos operativos y regulatorios [18]. Cuando un sistema automatizado identifica una transacción como sospechosa, las instituciones financieras deben poder justificar esta decisión ante reguladores, auditores y potencialmente ante autoridades judiciales. Una predicción sin explicación es insuficiente; se requiere evidencia comprensible sobre qué patrones específicos justificaron la alerta [5, 13].
La Inteligencia Artificial Explicable (*Explainable AI*, XAI) surge como respuesta a esta necesidad, buscando desarrollar métodos que generen explicaciones comprensibles de las decisiones de modelos complejos sin sacrificar su rendimiento predictivo [14]. En el contexto de GNNs, las explicaciones típicamente buscan identificar qué subgrafo (conjunto de nodos y aristas) es más relevante para la predicción de un nodo específico. La presente investigación considera tres métodos XAI que representan paradigmas complementarios: GNNExplainer (optimización local), PGExplainer (generación parametrizada) y GNNShap (teoría de juegos cooperativos).

3.4.2 GNNExplainer: Explicación por Optimización Local

GNNExplainer, propuesto por Ying et al., formula la explicación como un problema de optimización que identifica el subgrafo más compacto que maximiza la predicción del modelo para la clase objetivo [15]. Formalmente, el objetivo es:

$$\max_{G_S} MI(Y, (G_S, X_S)) = H(Y) - H(Y|G = G_S, X = X_S)$$

donde G_S es el subgrafo explicativo, X_S son las características relevantes y MI denota información mutua. GNNExplainer aprende una máscara continua sobre aristas y características mediante optimización basada en gradientes, y luego discretiza esta máscara para producir el subgrafo explicativo final.
La principal ventaja de GNNExplainer es su flexibilidad: al optimizar para cada instancia de forma independiente, puede adaptarse a la estructura local específica de cada nodo. Sin embargo, esta misma independencia constituye una fuente potencial de inestabilidad, ya que la optimización puede converger a diferentes óptimos locales en distintas ejecuciones, generando explicaciones diferentes para la misma instancia.

3.4.3 PGExplainer: Explicación Parametrizada

PGExplainer, propuesto por Luo et al., introduce un enfoque parametrizado que aprende una función generadora de explicaciones [16]. A diferencia de GNNExplainer, que optimiza para cada instancia independientemente, PGExplainer entrena una red neuronal que predice las probabilidades de importancia de las aristas:

$$P(e_{ij}) = \sigma(\mathrm{MLP}([\mathbf{h}_i \,\|\, \mathbf{h}_j]))$$

Esta formulación permite amortización: una vez entrenado, PGExplainer genera explicaciones en tiempo constante sin optimización adicional. La naturaleza parametrizada de PGExplainer introduce una hipótesis relevante para esta investigación: al aprender una función global de generación de explicaciones, este método podría exhibir mayor consistencia entre ejecuciones que GNNExplainer, ya que no depende de la convergencia de una optimización local. No obstante, esta ventaja teórica aún no ha sido verificada de forma rigurosa bajo condiciones de desbalance extremo en el dominio AML.

3.4.4 GNNShap: Explicación Basada en Valores de Shapley

GNNShap, propuesto por Akkas y Azad, adapta los valores de Shapley del dominio tabular al contexto de grafos [17]. Para cada arista, GNNShap calcula su contribución marginal promedio sobre todas las posibles coaliciones de aristas:

$$\phi_{ij} = \sum_{S \subseteq E \setminus \{e_{ij}\}} \frac{|S|!(|E| - |S| - 1)!}{|E|!} [f(S \cup \{e_{ij}\}) - f(S)]$$

donde $f(S)$ es la predicción del modelo cuando solo las aristas en S están presentes. Esta formulación garantiza propiedades teóricas deseables: eficiencia (las contribuciones suman la predicción total), simetría (aristas con contribuciones idénticas reciben valores iguales) y aditividad. Estas garantías axiomáticas hacen de GNNShap un candidato teóricamente robusto para producir explicaciones estables, aunque el costo computacional de la estimación exacta de los valores de Shapley requiere técnicas de aproximación mediante muestreo.

3.4.5 El Problema de la Estabilidad Explicativa

Estudios recientes han revelado que las explicaciones generadas por métodos XAI para GNNs pueden ser altamente inestables: explicaciones para la misma instancia varían significativamente entre ejecuciones, bajo pequeñas perturbaciones del modelo o frente a cambios mínimos en los datos [18–20].

Gawantka et al. propusieron métricas formales para cuantificar esta inestabilidad, mostrando que explicadores ampliamente usados exhiben variabilidad preocupante en sus salidas [18]. Agarwal et al. demostraron que muchas explicaciones consideradas “plausibles” no son necesariamente fieles al mecanismo interno del modelo [19]. Kosan et al., mediante un *benchmark* exhaustivo, evidenciaron que el desempeño de explicadores depende fuertemente del protocolo de evaluación [20].

En el contexto AML, esta inestabilidad es particularmente problemática. Una explicación inestable carece de valor operativo: si el subgrafo explicativo cambia radicalmente en cada ejecución, ninguna de las explicaciones puede considerarse como soporte confiable

para decisiones regulatorias. Esta limitación constituye el núcleo motivacional de la presente investigación: evaluar sistemáticamente cómo el desbalance extremo de datos —característico de escenarios AML reales— afecta la estabilidad de las explicaciones generadas por los tres métodos XAI presentados, aplicados a las cuatro arquitecturas GNN descritas.

3.5 Estrategias de Mitigación del Desbalance de Clases

3.5.1 El Problema del Desbalance en Detección AML

En escenarios reales de detección de fraude financiero, la clase positiva (transacciones ilícitas) representa una fracción mínima del total de transacciones, pudiendo alcanzar razones de desbalance de 1:1000 o más severas [23]. Este desbalance extremo genera múltiples desafíos para el entrenamiento de modelos de ML. Los algoritmos de optimización tienden a minimizar el error total, lo que en presencia de desbalance severo resulta en modelos que clasifican casi todo como la clase mayoritaria (benigna), ignorando la clase minoritaria (fraude). Además, la exactitud (*accuracy*) se convierte en una métrica engañosa: un clasificador trivial que prediga siempre "benigno" puede alcanzar 99,9% de exactitud en un escenario 1:1000, a pesar de no detectar ningún fraude. A nivel de optimización, los gradientes dominados por la clase mayoritaria dificultan el aprendizaje de patrones característicos de la clase minoritaria durante el entrenamiento con *backpropagation*.

3.5.2 GraphSMOTE: Sobremuestreo Topológico

GraphSMOTE constituye una adaptación del algoritmo SMOTE (*Synthetic Minority Over-sampling TEchnique*) al contexto de grafos, diseñada para balancear *datasets* donde las instancias tienen dependencias estructurales [25]. A diferencia de SMOTE tabular, que genera instancias sintéticas mediante interpolación lineal en el espacio de características, GraphSMOTE considera tanto los atributos de los nodos como la topología del grafo.
El algoritmo opera en tres etapas secuenciales. Primero, identifica nodos de la clase minoritaria que tienen al menos un vecino de la clase mayoritaria (nodos frontera), los cuales son candidatos prioritarios para sobremuestreo pues se encuentran en regiones donde la separación entre clases es ambigua. Segundo, para cada nodo frontera v_i, selecciona k vecinos más cercanos dentro de la clase minoritaria y genera un nodo sintético mediante interpolación: $\mathbf{x}_{\text{syn}} = \mathbf{x}_i + \lambda(\mathbf{x}_j - \mathbf{x}_i)$ con $\lambda \sim U(0, 1)$. Tercero, conecta el nodo sintético a sus k' vecinos más cercanos en el espacio de características, actualizando la estructura del grafo.
GraphSMOTE ha demostrado efectividad en balancear *datasets* de grafos, pero introduce dos preguntas críticas para esta investigación: ¿los nodos sintéticos mejoran o distorsionan las explicaciones? ¿La topología modificada refleja patrones reales de fraude o artefactos del algoritmo? Cabe señalar que, por consideraciones de viabilidad experimental, GraphSMOTE ha sido excluido de la primera versión del diseño experimental, aunque su inclusión se contempla como línea de trabajo futuro en el Capítulo 8.

3.5.3 Ponderación de Clases y Funciones de Pérdida

Una alternativa al sobremuestreo es ajustar la función de pérdida para penalizar diferentemente los errores en cada clase. La *cross-entropy* ponderada asigna pesos inversamente proporcionales

a la frecuencia de clase:

$$\mathcal{L}_{\text{weighted}} = -\sum_{i=1}^{N} w_{y_i} \log p_{y_i}(\mathbf{x}_i), \quad w_c = \frac{N}{k \cdot N_c}$$

donde N_c es el número de instancias de la clase c, N es el total de instancias y k es el número de clases.
La *Focal Loss*, propuesta originalmente para detección de objetos con clases desbalanceadas, reduce el peso de ejemplos bien clasificados y enfoca el aprendizaje en casos difíciles:

$$\mathcal{L}_{\text{focal}} = -\sum_{i=1}^{N} \alpha_{y_i}(1 - p_{y_i}(\mathbf{x}_i))^{\gamma} \log p_{y_i}(\mathbf{x}_i)$$

El término $(1-p_{y_i})^{\gamma}$ reduce la contribución de ejemplos fáciles cuando p_{y_i} es alta, mientras que α_{y_i} balancea la importancia entre clases. Estas dos estrategias —ponderación de clases y *Focal Loss*— junto con la ausencia de intervención (ninguna técnica de balanceo), constituyen los tres niveles del factor de balanceo en el diseño experimental de esta tesis. A diferencia de GraphSMOTE, estas estrategias no alteran la topología del grafo, lo que las hace particularmente relevantes para esta investigación: al preservar la estructura original, permiten evaluar el efecto del ajuste de la función de pérdida sobre la estabilidad explicativa sin introducir confusiones derivadas de la modificación topológica.

3.6 Formalización de Métricas de Evaluación

Para garantizar un análisis riguroso en los capítulos posteriores, resulta indispensable formalizar matemáticamente las métricas que permitirán cuantificar tanto el desempeño predictivo del modelo frente al desbalance extremo, como la estabilidad de las explicaciones generadas por los métodos XAI.

3.6.1 Métricas Fundamentales de Clasificación

En los problemas de clasificación binaria como la detección de fraude, el rendimiento de un modelo se evalúa inicialmente a través de la matriz de confusión, la cual tabula las predicciones frente a los valores reales. A partir de esta matriz se definen cuatro componentes básicos: Verdaderos Positivos (TP), Falsos Positivos (FP), Verdaderos Negativos (TN) y Falsos Negativos (FN). Utilizando estos valores se construyen las métricas de rendimiento elementales. La precisión (*Precision*) mide la proporción de alertas de fraude generadas por el modelo que son genuinas: Precision $= TP/(TP+FP)$. La exhaustividad o sensibilidad (*Recall*) mide la proporción del total de fraudes reales que el modelo logró detectar: Recall $= TP/(TP+FN)$. La especificidad (*Specificity*) mide la proporción de transacciones legítimas que fueron correctamente identificadas como tales: Specificity $= TN/(TN+FP)$.
Aunque estas métricas proporcionan información valiosa sobre el comportamiento del modelo, evaluarlas de manera aislada o depender de la exactitud global (*accuracy*) resulta altamente engañoso en contextos de desbalance extremo. En estos escenarios, un clasificador trivial que prediga siempre la clase mayoritaria obtendría una exactitud casi perfecta, pero su utilidad operativa para detectar el lavado de dinero sería nula [23].

3.6.2 Métricas de Rendimiento Predictivo en Escenarios de Desbalance

Para abordar las deficiencias de las métricas tradicionales frente al sesgo de la clase mayoritaria, la literatura especializada en detección de fraude recomienda emplear métricas compuestas que integren el desempeño sobre la clase minoritaria y penalicen el desequilibrio entre los errores predictivos.
El F1-Score (calculado sobre la clase minoritaria) es la media armónica entre la precisión y la exhaustividad. A diferencia de la media aritmética, la media armónica penaliza fuertemente los valores bajos, de modo que un modelo solo obtendrá un F1-Score alto si tanto su precisión como su exhaustividad son elevadas de manera simultánea:

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

El área bajo la curva Precision-Recall (PR-AUC) evalúa la relación directa entre la precisión y la exhaustividad en distintos umbrales de decisión. A diferencia de la curva ROC, que tiende a mostrar un rendimiento inflado en conjuntos de datos desbalanceados debido a la abundancia masiva de verdaderos negativos, un área PR-AUC alta indica que el modelo es capaz de detectar la mayoría de las transacciones ilícitas sin generar un volumen inmanejable de falsas alarmas [5].
El Coeficiente de Correlación de Matthews (MCC) es ampliamente considerado una de las métricas más robustas frente a clases extremadamente desbalanceadas. Evalúa la calidad de la predicción utilizando los cuatro cuadrantes de la matriz de confusión y produce un valor entre -1 y 1, donde 1 representa una predicción perfecta, 0 indica una predicción aleatoria y -1 una discordancia total:

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

Su principal ventaja es que solo arroja un puntaje alto si el modelo se desempeña bien en ambas clases, mitigando la influencia del desbalance.

3.6.3 Métricas de Estabilidad y Fidelidad Explicativa

La estabilidad de un método XAI se refiere a su capacidad para producir explicaciones consistentes en diferentes ejecuciones o frente a pequeñas perturbaciones en el modelo o en los datos [18]. En el contexto de GNNs, la explicación para un nodo de interés suele representarse como un subgrafo $G_S = (V_S, E_S)$ extraído del grafo original G, generalmente seleccionando el subconjunto de las K aristas más relevantes (*Top-K*).
Para cuantificar rigurosamente la variación estructural de estas explicaciones, esta investigación emplea el Índice de Similitud de Jaccard. Si un explicador se ejecuta dos veces independientes sobre el mismo nodo generando dos conjuntos de aristas explicativas E_{S_1} y E_{S_2}, el índice de Jaccard se define como:

$$J(E_{S_1}, E_{S_2}) = \frac{|E_{S_1} \cap E_{S_2}|}{|E_{S_1} \cup E_{S_2}|}$$

Un valor de $J = 1$ indica una estabilidad explicativa perfecta (la topología del subgrafo explicativo fue idéntica en ambas instancias), mientras que $J = 0$ indica inestabilidad total (no hay superposición en las aristas identificadas como relevantes).

Complementariamente a la estabilidad, resulta indispensable evaluar si la explicación refleja fidedignamente el mecanismo interno de la red neuronal mediante la fidelidad (*Fidelity*). Esta métrica cuantifica la caída en la probabilidad asignada a la clase predicha $\hat{y}$ cuando el subgrafo explicativo G_S es removido (enmascarado) del grafo original:

$$\text{Fidelity} = \frac{1}{N} \sum_{i=1}^{N} \left(P(\hat{y}_i \mid G_i) - P(\hat{y}_i \mid G_i \setminus G_{S_i}) \right)$$

Una fidelidad alta garantiza que las aristas identificadas por el método XAI eran, efectivamente, la señal topológica de la cual dependía la GNN para realizar su predicción [19]. La combinación de estabilidad (Jaccard) y fidelidad permite distinguir entre explicaciones que son consistentes pero irrelevantes, y explicaciones que son relevantes pero inconsistentes, dos modos de fallo que tienen implicaciones operativas distintas.

3.7 Preparación para el Diseño Experimental

Este capítulo ha establecido los fundamentos técnicos y matemáticos necesarios para comprender el diseño metodológico que se desarrollará en el Capítulo 4. La progresión conceptual —de ML tabular a DL, de DL a GNNs, de GNNs a XAI, y de XAI a la cuestión de la estabilidad bajo desbalance— refleja la estructura lógica del problema de investigación planteado en el Capítulo 1.

Las cuatro arquitecturas presentadas (GCN, GraphSAGE, GAT, TAGCN) cubren un espectro representativo de mecanismos de agregación. Los tres explicadores seleccionados (GNNExplainer, PGExplainer, GNNShap) representan paradigmas complementarios de generación de explicaciones. Las tres estrategias de balanceo (ninguna, ponderación de clases, *Focal Loss*) permiten evaluar el efecto de la intervención sobre la función de pérdida sin alterar la topología del grafo. Finalmente, las métricas formalizadas (F1-Score, MCC, PR-AUC para rendimiento predictivo; Jaccard y Fidelidad para estabilidad explicativa) proporcionan un marco de evaluación robusto que integra las dos dimensiones centrales de esta investigación. El siguiente capítulo construirá sobre estos fundamentos para desplegar el diseño metodológico completo de la investigación.

Capítulo 4

METODOLOGÍA

Este capítulo presenta el diseño metodológico completo de la investigación. A diferencia de los capítulos precedentes, que establecieron los fundamentos teóricos y conceptuales, este capítulo describe con precisión el conjunto de datos utilizado, el pipeline experimental implementado, la infraestructura computacional empleada y cada una de las decisiones de diseño que configuran la matriz experimental de 144 combinaciones. La rigurosidad en la descripción del método resulta esencial para garantizar la reproducibilidad del estudio y para permitir a otros investigadores replicar o extender los resultados presentados en el Capítulo 5.

4.1 Conjunto de Datos: Elliptic Bitcoin Dataset

4.1.1 Descripción General y Procedencia

Esta investigación emplea el Elliptic Bitcoin Dataset, uno de los pocos grafos de transacciones financieras reales con etiquetas de actividad ilícita disponibles para la comunidad científica. El dataset fue recopilado por la empresa de analítica blockchain Elliptic en colaboración con investigadores del MIT Lincoln Laboratory y publicado por Weber et al. en 2019 [6]. Cada nodo del grafo representa una transacción en la red Bitcoin, y cada arista dirigida indica un flujo de bitcoins entre transacciones. La estructura resultante es un grafo dirigido que captura la topología de los movimientos de valor en la blockchain.
El grafo contiene 203,769 nodos y 234,355 aristas. Cada nodo posee un vector de 166 atributos numéricos, de los cuales los primeros 94 corresponden a características locales de la transacción (monto, comisiones, número de entradas y salidas, entre otras) y los restantes 72 son características agregadas del vecindario de un salto (medias, varianzas, correlaciones de los atributos de las transacciones directamente conectadas). Las identidades de las transacciones fueron anonimizadas por Elliptic para proteger la privacidad de los usuarios, de modo que los nombres de las 166 características no son públicos. El dataset abarca un periodo de aproximadamente dos semanas de actividad en la red Bitcoin, segmentado en 49 intervalos temporales (timesteps) que reflejan el orden cronológico de las transacciones.
Del total de nodos, 42,019 poseen etiquetas conocidas: 4,545 fueron clasificados como ilícitos (vinculados a actividades como fraude, ransomware, mercados oscuros y esquemas Ponzi) y 37,474 fueron clasificados como lícitos (exchanges, servicios de custodia, proveedores de pagos). Los restantes 161,750 nodos permanecen sin etiquetar y constituyen la clase desconocida. Esta distribución genera un desbalance inherente de aproximadamente 1:9

entre nodos ilícitos y lícitos dentro del subconjunto etiquetado, una proporción que resulta aún más extrema si se considera el total de nodos del grafo, donde los nodos ilícitos representan menos del 2% [6].

4.1.2 División Temporal de los Datos

La partición de los datos sigue un esquema estrictamente temporal para respetar la causalidad inherente al problema de detección de fraude. Utilizar una partición aleatoria (random split) violaría la estructura temporal del grafo y produciría una sobreestimación del rendimiento predictivo, ya que el modelo tendría acceso a información futura durante el entrenamiento [6]. La partición implementada en este trabajo asigna los timesteps 1 a 34 al conjunto de entrenamiento (aproximadamente el 70% de los nodos etiquetados), los timesteps 35 a 42 al conjunto de validación (aproximadamente el 15%), y los timesteps 43 a 49 al conjunto de prueba (el 15% restante). Esta distribución preserva la progresión cronológica y garantiza que la evaluación del modelo refleje su capacidad de generalización hacia transacciones futuras, un requisito operativo fundamental para cualquier sistema de monitoreo de transacciones.
Solo los nodos con etiquetas conocidas (lícitas o ilícitas) participan en las máscaras de entrenamiento, validación y prueba. Los nodos sin etiquetar permanecen en el grafo durante el entrenamiento transductivo —sus atributos y aristas contribuyen al proceso de message passing— pero no generan señal de supervisión ni participan en el cálculo de las métricas de evaluación.

4.1.3 Normalización de Atributos

Previo al entrenamiento, todos los atributos de los nodos se normalizan mediante un StandardScaler (media cero, desviación estándar unitaria). El ajuste del escalador se realiza exclusivamente sobre los nodos del conjunto de entrenamiento para prevenir la fuga de información (*data leakage*) desde los conjuntos de validación y prueba. La transformación resultante se aplica a la totalidad de los nodos del grafo, incluyendo los nodos sin etiquetar, de modo que el proceso de message passing opere sobre distribuciones de atributos homogéneas.

4.2 Construcción de los Escenarios de Desbalance

4.2.1 Justificación de los Escenarios

El desbalance inherente del Elliptic Dataset (aproximadamente 1:9 entre ilícitos y lícitos en el subconjunto etiquetado) representa una condición relativamente moderada en comparación con los escenarios operativos reales del sector financiero, donde las transacciones sospechosas pueden constituir menos del 0,1% del volumen total [32]. Para evaluar la degradación del rendimiento predictivo y la estabilidad explicativa bajo condiciones progresivamente más severas, esta investigación define cuatro escenarios de desbalance controlado que abarcan desde la paridad perfecta hasta una ratio extrema de 1:100.

4.2.2 Escenarios Definidos

Los cuatro escenarios de desbalance se construyen exclusivamente sobre la máscara de entrenamiento, preservando las máscaras de validación y prueba intactas para garantizar una evaluación no sesgada. La generación de escenarios emplea una estrategia dual de submuestreo que depende de la dirección del ajuste requerido.
Para el escenario 1:1 (balanceado), se realiza un submuestreo de nodos lícitos hasta igualar la cantidad de nodos ilícitos disponibles en el conjunto de entrenamiento. Todos los nodos ilícitos permanecen en la máscara y se selecciona aleatoriamente un subconjunto de nodos lícitos de tamaño equivalente. El escenario 1:10 (desbalance moderado) sigue la misma estrategia, reteniendo todos los nodos ilícitos y submuestreando los lícitos hasta alcanzar diez veces la cantidad de nodos ilícitos. Este escenario se aproxima a la distribución natural del dataset y sirve como referencia para comparar el efecto de las intervenciones de balanceo.
Los escenarios 1:50 y 1:100 (desbalance severo y extremo) invierten la dirección del submuestreo: dado que la proporción natural del dataset ya es más equilibrada que estas ratios objetivo, se retienen todos los nodos lícitos y se submuestrean los nodos ilícitos hasta alcanzar la proporción deseada. En el escenario 1:50, se conserva aproximadamente el 2% de los nodos ilícitos originales en el conjunto de entrenamiento, mientras que en el escenario 1:100 se conserva aproximadamente el 1%. Esta estrategia de submuestreo inverso simula las condiciones de extrema escasez de ejemplos positivos que caracterizan los entornos operativos de detección de lavado de dinero.
En todos los escenarios, la estructura topológica del grafo permanece intacta: no se eliminan nodos ni aristas del grafo subyacente, sino que se modifica únicamente la máscara de entrenamiento para controlar qué nodos contribuyen a la función de pérdida durante el entrenamiento. Esta decisión de diseño resulta fundamental para esta investigación, ya que permite aislar el efecto del desbalance de la señal de supervisión sin introducir alteraciones en la topología que podrían confundir la evaluación de la estabilidad explicativa.
La semilla aleatoria utilizada para el submuestreo es 42 en todas las configuraciones, garantizando la reproducibilidad exacta de cada escenario.

4.3 Arquitecturas GNN Evaluadas

4.3.1 Configuración Común

Las cuatro arquitecturas evaluadas comparten una estructura general compuesta por capas de convolución grafal apiladas, funciones de activación no lineales y regularización por dropout. Cada modelo recibe como entrada el vector de 166 atributos de cada nodo y produce un vector de salida bidimensional que representa los logits para las clases lícita e ilícita. El entrenamiento se realiza en modo transductivo y *full-batch*: en cada época, la totalidad del grafo participa en el proceso de message passing, y la función de pérdida se calcula exclusivamente sobre los nodos señalados por la máscara de entrenamiento del escenario correspondiente.
Los hiperparámetros base comunes a todas las arquitecturas en la ejecución principal del pipeline son: dimensión oculta de 128 unidades, dos capas de convolución, tasa de dropout de 0,3, optimizador Adam con tasa de aprendizaje de 0,001, y un máximo de 300 épocas con early stopping basado en el MCC de validación y una paciencia de 20 épocas.

4.3.2 GCN (Graph Convolutional Network)

La implementación de GCN sigue la formulación espectral de Kipf y Welling (2017) [33] mediante capas GCNConv de PyTorch Geometric. Cada capa aplica una convolución espectral con normalización simétrica de la matriz de adyacencia, seguida de una activación ReLU y dropout. La primera capa transforma el espacio de entrada (166 dimensiones) al espacio oculto (128 dimensiones), y la capa final proyecta del espacio oculto a las dos clases de salida.

4.3.3 GraphSAGE (Sample and Aggregate)

GraphSAGE se implementa utilizando capas SAGEConv con agregación por media (*mean aggregation*), siguiendo el diseño de Hamilton, Ying y Leskovec (2017) [34]. A diferencia de GCN, GraphSAGE aprende una función de agregación que concatena la representación del nodo central con la media de las representaciones de sus vecinos, lo que le confiere la capacidad de producir embeddings para nodos no observados durante el entrenamiento. La estructura de capas, activaciones y dropout es análoga a la de GCN.

4.3.4 GAT (Graph Attention Network)

La implementación de GAT emplea capas GATConv con mecanismos de atención multi-cabeza, de acuerdo con la formulación de Velickovic et al. (2018) [35]. Las capas intermedias utilizan cuatro cabezas de atención con concatenación de las salidas, de modo que cada capa intermedia produce un vector de dimensión $128 \times 4 = 512$. La capa final emplea una única cabeza con promediado (en lugar de concatenación) para producir los dos logits de salida. La función de activación entre capas intermedias es ELU en lugar de ReLU, siguiendo la especificación original de GAT. El dropout se aplica tanto a los atributos de los nodos como a los coeficientes de atención.

4.3.5 TAGCN (Topology Adaptive Graph Convolutional Network)

TAGCN se implementa mediante capas TAGConv con orden de filtro polinomial $K = 3$, siguiendo la arquitectura de Du et al. (2017) [12] y la validación de He et al. (2026) para el Elliptic Dataset [13]. Cada capa TAGConv aprende un filtro polinomial de orden K sobre la matriz de adyacencia, lo que permite capturar patrones topológicos a múltiples escalas dentro de una misma capa. Con $K = 3$, cada capa agrega información del vecindario hasta tres saltos de distancia, otorgando a TAGCN un campo receptivo efectivo mayor que el de GCN o GraphSAGE con el mismo número de capas. La estructura de activaciones y dropout sigue el patrón común ReLU + Dropout.

4.4 Técnicas de Mitigación del Desbalance

4.4.1 Línea Base Sin Balanceo

La configuración sin balanceo utiliza la función de pérdida CrossEntropyLoss estándar de PyTorch, donde todas las clases reciben igual ponderación. Esta configuración establece la línea base contra la cual se evalúa el efecto de las técnicas de mitigación. Bajo desbalance extremo, el gradiente de la función de pérdida estará dominado por la clase mayoritaria

(lícita), lo que puede conducir a modelos que trivialmente predicen la clase mayoritaria para todos los nodos.

4.4.2 Ponderación de Clases (Class Weighting)

La ponderación de clases ajusta la contribución de cada clase a la función de pérdida de manera inversamente proporcional a su frecuencia en el conjunto de entrenamiento. Los pesos se calculan mediante la fórmula $w_c = N/(C \cdot n_c)$, donde N es el número total de nodos en la máscara de entrenamiento, C es el número de clases y n_c es el número de nodos de la clase c. Estos pesos se inyectan como parámetro de la CrossEntropyLoss de PyTorch, amplificando el gradiente generado por los nodos ilícitos (clase minoritaria) sin alterar la topología del grafo ni la función de pérdida subyacente.

4.4.3 Focal Loss

Focal Loss, propuesta por Lin et al. (2017) [36], modifica la CrossEntropy estándar mediante un factor de modulación $(1 - p_t)^\gamma$ que reduce la contribución de los ejemplos fácilmente clasificados y concentra el gradiente en los ejemplos difíciles cercanos al límite de decisión. La implementación utiliza los parámetros $\gamma = 2{,}0$ y $\alpha = 0{,}25$, donde α pondera la importancia relativa de la clase positiva (ilícita). Estos valores siguen la configuración original de Lin et al. y se aplican uniformemente en todas las configuraciones experimentales. A diferencia de la ponderación de clases, que actúa exclusivamente sobre la frecuencia relativa de las clases, Focal Loss opera sobre la confianza de cada predicción individual, lo que potencialmente ofrece una señal de gradiente más informativa para los nodos ilícitos que el modelo clasifica con baja certeza.

4.4.4 Exclusión de GraphSMOTE

GraphSMOTE [25] fue considerada inicialmente como técnica de aumento de datos a nivel de grafo, pero se excluye de la primera versión de este estudio. La razón principal es que GraphSMOTE introduce nodos sintéticos y aristas artificiales en el grafo, lo que altera la topología de entrada de las GNNs. Dado que el objetivo central de esta investigación es evaluar la estabilidad de las explicaciones topológicas bajo distintas condiciones de desbalance, la introducción de estructura artificial representaría una variable confusora que impediría atribuir las variaciones en la estabilidad exclusivamente al nivel de desbalance o a la elección del explicador. La evaluación de GraphSMOTE se plantea como extensión futura en el Capítulo 8.

4.5 Métodos de Explicabilidad (XAI)

4.5.1 Selección de Nodos a Explicar

Para cada configuración de entrenamiento (escenario, arquitectura, técnica de balanceo), se selecciona un subconjunto de nodos del conjunto de prueba sobre los cuales se generan las explicaciones. En la configuración por máquina, se seleccionan 30 nodos ilícitos del conjunto de prueba utilizando un muestreo aleatorio con semilla fija (42) para garantizar que las mismas transacciones se explican en todas las configuraciones. La restricción a nodos ilícitos responde al foco operativo de la investigación: la estabilidad de las

explicaciones resulta particularmente relevante para las alertas positivas que un analista humano debería revisar en un entorno de producción.

4.5.2 Configuración de GNNExplainer

GNNExplainer [15] se ejecuta utilizando la API nativa de PyTorch Geometric (`torch_geometric.expla` Para cada nodo a explicar, el algoritmo optimiza una máscara suave sobre las aristas del subgrafo computacional y una máscara sobre los atributos del nodo, maximizando la información mutua entre la distribución original del modelo y la distribución condicionada al subgrafo explicativo. La configuración utiliza 200 épocas de optimización con una tasa de aprendizaje de 0,01, generando explicaciones a nivel de modelo (`explanation_type="model"`) con máscaras tanto para aristas (`edge_mask_type="object"`) como para atributos (`node_mask_type="a`

4.5.3 Configuración de PGExplainer

PGExplainer [16] se diferencia de GNNExplainer en que entrena una red neuronal paramétrica (MLP) que aprende a generar máscaras de aristas para cualquier nodo, en lugar de optimizar una máscara independiente por nodo. Esta naturaleza paramétrica tiene implicaciones directas para el protocolo de estabilidad: PGExplainer se entrena una vez por réplica (no por nodo), y luego genera explicaciones para todos los nodos seleccionados. El entrenamiento utiliza 30 épocas con una tasa de aprendizaje de 0,003, y se ejecuta sobre un subconjunto de 100 nodos de entrenamiento por eficiencia. Las explicaciones se generan en modo `explanation_type="phenomenon"`, donde el explicador se entrena para explicar la predicción del modelo sobre la clase real del nodo, proporcionando la etiqueta verdadera como objetivo.

4.5.4 Configuración de GNNShap

GNNShap [17] calcula valores SHAP aproximados para cada nodo mediante un esquema de muestreo por permutaciones. Para cada permutación, los atributos del nodo se enmascaran progresivamente (reemplazándolos por la media global de cada atributo) y se mide la contribución marginal de cada atributo a la probabilidad predicha de la clase ilícita. La implementación utiliza 50 muestras de permutación por nodo en las configuraciones por máquina, un compromiso entre la precisión de la estimación y el costo computacional. A diferencia de GNNExplainer y PGExplainer, GNNShap no genera máscaras de aristas sino rankings de importancia de atributos, por lo que las métricas de estabilidad topológica (Jaccard) no son aplicables a este método; la evaluación de estabilidad se basa exclusivamente en la correlación de Spearman entre rankings y en la métrica de SHAP Concentration.

4.6 Protocolo de Evaluación de Estabilidad

4.6.1 Test Estocástico (Stochastic Stability)

El test de estabilidad estocástica constituye el protocolo central de esta investigación. Para cada combinación de configuración y método XAI, se ejecutan 20 réplicas independientes del explicador sobre cada nodo seleccionado, variando únicamente la semilla aleatoria que inicializa el proceso de optimización del explicador. Las semillas se generan mediante la fórmula $s_r = 42 + r \times 17$ para $r = 0, 1, \ldots, 19$, produciendo una secuencia determinista

pero suficientemente dispersa. Para GNNExplainer, cada réplica re-optimiza la máscara de aristas y atributos desde cero con la nueva semilla. Para PGExplainer, cada réplica re-entrena la MLP paramétrica completa antes de generar las explicaciones para todos los nodos. Para GNNShap, cada réplica re-ejecuta el muestreo por permutaciones con la nueva semilla.
De las $R = 20$ réplicas por nodo se obtienen R subgrafos explicativos (para GNNExplainer y PGExplainer) y R rankings de importancia de atributos (para los tres métodos). La estabilidad se cuantifica mediante comparaciones por pares: el Índice de Jaccard se calcula sobre los $\binom{R}{2} = 190$ pares posibles de subgrafos, y la correlación de Spearman se calcula sobre los 190 pares posibles de rankings de atributos. Se reporta la media y la desviación estándar de estas comparaciones por pares para cada nodo, y posteriormente se agregan los valores promedio por nodo para obtener la estabilidad global de cada configuración.

4.6.2 Test de Perturbación (Perturbation Stability)

El test de perturbación evalúa la sensibilidad de las explicaciones frente a modificaciones mínimas en los atributos de entrada. Para cada nodo seleccionado, se genera una explicación de referencia con la semilla base (42) y luego se producen 10 versiones perturbadas del vector de atributos del nodo, inyectando ruido gaussiano $\mathcal{N}(0, \sigma^2)$ para tres niveles de intensidad: $\sigma \in \{0{,}01,\ 0{,}05,\ 0{,}10\}$. Para cada versión perturbada se genera una nueva explicación y se compara contra la explicación de referencia utilizando el Índice de Jaccard (para los subgrafos) y la correlación de Spearman (para los rankings). Este protocolo permite cuantificar la robustez de cada método XAI frente a variaciones infinitesimales en los datos de entrada, un aspecto relevante para la confiabilidad operativa de las explicaciones.

4.6.3 Extracción de Subgrafos y Rankings

Para calcular las métricas de estabilidad, las explicaciones generadas por cada método se procesan de forma estandarizada. En el caso de GNNExplainer y PGExplainer, se extrae el subgrafo explicativo seleccionando las $K = 20$ aristas con mayores pesos en la máscara de aristas (*Top-K edges*). Estas aristas conforman un conjunto de pares ordenados que se compara mediante el Índice de Jaccard. Adicionalmente, se extrae un ranking de importancia de atributos a partir de la máscara de atributos (GNNExplainer) o de los valores SHAP (GNNShap), ordenando los atributos de mayor a menor importancia. Los rankings se comparan mediante la correlación de Spearman sobre los $K = 20$ atributos más relevantes.

4.7 Métricas de Evaluación

4.7.1 Métricas Predictivas

El rendimiento predictivo de cada configuración se evalúa sobre el conjunto de prueba (timesteps 43–49) utilizando tres métricas complementarias, todas ellas formalizadas en la Sección 3.6 del Capítulo 3. El F1-Score se calcula sobre la clase ilícita (positiva) para capturar la capacidad del modelo de identificar transacciones sospechosas sin generar un exceso de falsos positivos. El MCC (Matthews Correlation Coefficient) proporciona una evaluación balanceada que utiliza los cuatro cuadrantes de la matriz de confusión, lo que lo

hace particularmente robusto frente al desbalance extremo. El PR-AUC (Precision-Recall Area Under Curve) evalúa la relación entre precisión y exhaustividad a través de múltiples umbrales de decisión. El criterio de early stopping y la selección de hiperparámetros se basan en el MCC de validación, siguiendo las recomendaciones de la literatura sobre métricas robustas para datos desbalanceados [23].

4.7.2 Métricas de Estabilidad

La estabilidad de las explicaciones se cuantifica mediante el Índice de Jaccard para la superposición de subgrafos explicativos ($J \in [0, 1]$, donde $J = 1$ indica estabilidad perfecta) y la correlación de Spearman para la concordancia de rankings de atributos ($\rho \in [-1, 1]$, donde $\rho = 1$ indica concordancia total). Ambas métricas se calculan por pares sobre las réplicas estocásticas y se reportan como media y desviación estándar agregadas por nodo y por configuración. Adicionalmente, para GNNShap se calcula la SHAP Concentration (He et al., 2026) [13], que mide la fracción de la atribución total concentrada en los 10 atributos más relevantes: una concentración alta indica que el modelo depende de pocas características, facilitando la auditabilidad.

4.8 Optimización de Hiperparámetros

El pipeline incluye un módulo de optimización de hiperparámetros basado en Optuna con el muestreador TPE (Tree-structured Parzen Estimator) y semilla fija 42 para reproducibilidad. El espacio de búsqueda abarca cuatro dimensiones comunes a todas las arquitecturas: dimensión oculta $\in \{64, 128, 256\}$, número de capas $\in \{2, 3\}$, tasa de dropout $\in \{0{,}1,\ 0{,}2,\ 0{,}3,\ 0{,}5\}$, y tasa de aprendizaje $\in [10^{-4},\ 10^{-2}]$ en escala logarítmica. Para GAT se incluye adicionalmente el número de cabezas de atención $\in \{4, 8\}$, y para TAGCN el orden del filtro polinomial $K \in \{2, 3, 4\}$. La función objetivo maximiza el MCC de validación, y cada estudio ejecuta 20 trials por combinación de arquitectura y técnica de balanceo. Cada trial entrena el modelo durante un máximo de 200 épocas con early stopping de 20 épocas. Los mejores hiperparámetros identificados por Optuna se utilizan para el entrenamiento final reportado en los resultados.

4.9 Infraestructura Computacional y Distribución de la Carga

4.9.1 Configuración de Máquinas

La ejecución de la matriz experimental de 144 configuraciones se distribuyó entre tres máquinas con GPUs NVIDIA de distintas capacidades. La Máquina A (RTX 4090, 24 GB de VRAM) ejecutó las 72 configuraciones correspondientes a las arquitecturas GAT y TAGCN en los cuatro escenarios de desbalance con las tres técnicas de balanceo, multiplicadas por los tres métodos XAI. La Máquina B (RTX 4060, 8 GB de VRAM) ejecutó 36 configuraciones correspondientes a GCN y GraphSAGE en los escenarios 1:1 y 1:10. La Máquina C (RTX 3050 Laptop, 4 GB de VRAM) ejecutó las 36 configuraciones restantes de GCN y GraphSAGE en los escenarios 1:50 y 1:100.
Esta distribución responde a los requisitos de VRAM de cada arquitectura: GAT con cuatro cabezas de atención requiere aproximadamente tres veces más memoria que GCN

para el mismo grafo, y TAGCN con filtros de orden $K = 3$ tiene un consumo similar. Las arquitecturas más ligeras (GCN y GraphSAGE) se asignaron a las GPUs con menor capacidad. Cada máquina utiliza un archivo de configuración YAML independiente que especifica las arquitecturas, los escenarios y los parámetros de explicabilidad ajustados a su capacidad de memoria (50 muestras SHAP en lugar de 100 para las máquinas B y C).

4.9.2 Reproducibilidad y Reanudación

El pipeline implementa múltiples mecanismos de reproducibilidad y tolerancia a fallos. Todas las operaciones aleatorias (submuestreo de escenarios, inicialización de modelos, muestreo de permutaciones SHAP, generación de réplicas estocásticas) utilizan semillas fijas y explícitas. El entrenamiento guarda checkpoints de recuperación cada 10 épocas, almacenando no solo los pesos del modelo y el estado del optimizador, sino también los estados de los generadores aleatorios de PyTorch, NumPy y CUDA. El orquestador registra las configuraciones completadas mediante la clase ExperimentTracker, de modo que una ejecución interrumpida por señal SIGTERM o SIGINT puede reanudarse con la bandera `--resume`, omitiendo las configuraciones ya finalizadas sin duplicar resultados.

4.9.3 Tracking y Registro de Resultados

Los resultados se registran mediante un sistema dual de tracking. MLflow actúa como backend principal, organizando los resultados en una jerarquía de runs: un run padre por cada configuración de entrenamiento (que registra las métricas predictivas por época) y un run hijo por cada método XAI (que registra las métricas de estabilidad). Simultáneamente, un backup en formato CSV registra cada resultado como una fila con todas las métricas predictivas y de estabilidad, permitiendo la consulta y el análisis estadístico sin depender del servidor de MLflow. La fusión de resultados de las tres máquinas se realiza mediante un script dedicado que concatena los CSV, resuelve posibles duplicados con prioridad por timestamp (el resultado más reciente prevalece) y verifica la cobertura de la matriz experimental.

4.10 Análisis Estadístico

4.10.1 ANOVA Factorial

Para identificar los factores y las interacciones que afectan significativamente la estabilidad explicativa, se aplica un ANOVA factorial de tipo II con tres factores: Arquitectura (4 niveles), Técnica de Balanceo (3 niveles) y Método XAI (3 niveles). La variable dependiente es el Índice de Jaccard medio por configuración (o la correlación de Spearman para GNNShap, donde el Jaccard no es aplicable). El ANOVA proporciona los valores p para los efectos principales y las interacciones de segundo y tercer orden, así como los tamaños del efecto (η^2) calculados como la proporción de la suma de cuadrados de cada factor respecto a la suma de cuadrados total. Los efectos con $p < 0{,}05$ se consideran estadísticamente significativos.

4.10.2 Comparaciones Post-Hoc

Para los factores con efectos principales significativos en el ANOVA, se realizan comparaciones post-hoc mediante el test de Tukey HSD (*Honestly Significant Difference*) con un nivel de significancia de $\alpha = 0{,}05$. Este test identifica los pares específicos de niveles del factor que difieren significativamente entre sí, controlando la tasa de error familiar (*family-wise error rate*). El análisis se complementa con un estudio de degradación por escenario de desbalance, que calcula la media, la desviación estándar y los intervalos de confianza al 95% de las métricas de estabilidad agrupadas por escenario y arquitectura.

4.10.3 Matriz de Recomendación

La síntesis de resultados culmina en una matriz de recomendación que identifica las tríadas (arquitectura, explicador, técnica de balanceo) que satisfacen simultáneamente umbrales mínimos de rendimiento predictivo y estabilidad explicativa. Los umbrales definidos son: F1-Score $\geq 0{,}80$, MCC $\geq 0{,}70$ y Jaccard medio $\geq 0{,}70$. Las configuraciones que superan los tres umbrales se consideran candidatas viables para despliegue operativo. La confianza de cada recomendación se estima mediante intervalos de confianza bootstrap al 95% con 1,000 remuestreos.

4.11 Síntesis del Diseño Metodológico

La matriz experimental resultante comprende 144 configuraciones únicas: 4 escenarios de desbalance $\times$ 4 arquitecturas GNN $\times$ 3 técnicas de balanceo $\times$ 3 métodos XAI. Cada configuración involucra el entrenamiento de un modelo con optimización de hiperparámetros, la generación de explicaciones para 30 nodos ilícitos del conjunto de prueba, la ejecución de 20 réplicas estocásticas por nodo y la evaluación de tres niveles de perturbación. Este diseño permite responder a la pregunta central de la tesis —cómo se degrada la estabilidad explicativa bajo desbalance extremo y qué tríada la optimiza— mediante un análisis factorial riguroso que controla las interacciones entre los factores experimentales. El siguiente capítulo presenta los resultados obtenidos de la ejecución

Capítulo 5

RESULTADOS

Este capítulo presenta los resultados obtenidos de la ejecución del diseño metodológico descrito en el Capítulo 4. Se reportan los hallazgos tanto en rendimiento predictivo como en estabilidad explicativa para las 144 configuraciones de la matriz experimental.

5.1 Análisis Exploratorio de Datos

5.2 Descripción del Pipeline Experimental

5.2.1 Configuración de hiperparámetros

5.2.2 Infraestructura computacional

5.3 Escenarios de Desbalance

5.4 Resultados de Rendimiento Predictivo

5.4.1 Impacto del desbalance en el rendimiento

5.4.2 Comparación entre arquitecturas

5.4.3 Efecto de las técnicas de balanceo

5.5 Resultados de Estabilidad Explicativa

5.5.1 Estabilidad estocástica

5.5.2 Estabilidad ante perturbaciones

5.5.3 Fidelidad de las explicaciones

5.6 Análisis Factorial

5.7 Síntesis de Resultados

Capítulo 6

DISCUSIÓN

Este capítulo presenta un análisis crítico de los resultados obtenidos en el Capítulo 5, vinculándolos con el estado del arte revisado en el Capítulo 1, con los fundamentos técnicos desarrollados en el Capítulo 3 y con el diseño metodológico del Capítulo 4. La discusión se organiza en torno a los cuatro ejes principales de la investigación: el impacto del desbalance, la resiliencia arquitectónica, el efecto de las técnicas de balanceo y la identificación de configuraciones óptimas.

6.1 Degradación de la Estabilidad Explicativa bajo Desbalance

6.2 Resiliencia Arquitectónica: GCN vs. GraphSAGE vs. GAT vs. TAGCN

6.3 Impacto de las Estrategias de Balanceo sobre la Explicabilidad

6.4 Comparación entre Explicadores: GNNExplainer, PGExplainer y GNNShap

6.5 Hacia una Tríada Óptima

6.6 Implicaciones para la Industria AML

6.7 Limitaciones del Estudio

Capítulo 7

CONCLUSIONES

Este capítulo sintetiza los principales hallazgos de la investigación, articulando las respuestas a los objetivos específicos planteados y las contribuciones realizadas al estado del arte en la intersección de GNNs, XAI y detección AML bajo desbalance extremo.

7.1 Respuestas a los Objetivos de Investigación

7.1.1 Sobre el impacto del desbalance en la estabilidad explicativa

7.1.2 Sobre la resiliencia topológica de las arquitecturas GNN

7.1.3 Sobre el impacto de las estrategias de mitigación del desbalance

7.1.4 Sobre la matriz de recomendación técnica

7.2 Contribuciones Principales

7.3 Limitaciones Identificadas

Capítulo 8

PERSPECTIVAS FUTURAS Y ANEXOS

8.1 Perspectivas Futuras

8.1.1 Extensión a otros conjuntos de datos y dominios

8.1.2 Incorporación de GraphSMOTE y técnicas de sobremuestreo topológico

8.1.3 Arquitecturas dinámicas y temporales

8.1.4 Métricas de estabilidad adicionales

8.1.5 Integración con sistemas operativos de cumplimiento

8.1.6 Explicabilidad interactiva y centrada en el usuario

Anexos

Bibliografía

[1] U Kelkar. Addressing Illicit Financial Flows: International Legal Efforts to Strengthen Economic Stability. *Mayo Communication Journal*, 1(2):86–96, 2024.

[2] E Spotlight. *Cryptocurrencies: Tracing the Evolution of Criminal Finances*. Publications Office of the European Union, Luxembourg, 2021.

[3] R Subashi. Cryptocurrencies and Money Laundering. *Balkan Journal of Interdisciplinary Research*, 10(1), 2024. doi: 10.2478/bjir-2024-0005.

[4] H Almeida, P Pinto, and A Fernández Vilas. From Placement to Integration: A Parametric Study of Cryptocurrency-Based Money Laundering Techniques. *Risks*, 13(12):249, 2025. doi: 10.3390/risks13120249.

[5] E Unagar and B Borisaniya. Survey on Detection of Cryptocurrency Money Laundering and Its Explanation Using XAI. *SN Computer Science*, 6(3):291, 2025. doi: 10.1007/s42979-025-03828-2.

[6] Mark Weber, Giacomo Domeniconi, Jie Chen, Daniel Karl I Weidele, Claudio Bellei, Tom Robinson, and Charles E Leiserson. Anti-Money Laundering in Bitcoin: Experimenting with Graph Convolutional Networks for Financial Forensics. *ArXiv*, abs/1908.02591, 2019. URL `https://api.semanticscholar.org/CorpusID:199472611`.

[7] O Lawal, A Okolie, and C Obunadike. An explainable graph neural network framework for anti–money laundering in cryptocurrency transactions using the Elliptic dataset. *International Journal of Network Security & Its Applications*, 17 (6):27–39, 2025. doi: 10.5121/ijnsa.2025.17602.

[8] I Alarab and S Prakoonwit. Graph-based lstm for anti-money laundering: Experimenting temporal graph convolutional network with bitcoin data. *Neural Processing Letters*, 55(1):689–707, 2023. doi: 10.1007/s11063-022-10904-8.

[9] F Wan and P Li. A novel money laundering prediction model based on a dynamic graph convolutional neural network and long short-term memory. *Symmetry*, 16(3): 378, 2024. doi: 10.3390/sym16030378.

[10] B Cui and J Zhang. EG-SAN: Evolving Graph Self-attention Networks for Detecting Illicit Activities in Cryptocurrency. In *International Conference on Digital Forensics and Cyber Crime*, pages 24–38, Cham, 2024. doi: 10.1007/978-3-031-89360-5-2.

[11] Ziqian Lin, Qining Luo, Dongze Wu, Jie Shen, Lingying Li, Xunyi Nong, and Zhenkai Qin. Detecting illicit transactions in bitcoin: a wavelet-temporal graph transformer approach for anti-money laundering. *Scientific Reports*, 16(1):1548, 2026.

[12] Jian Du, Shanghang Zhang, Guanhang Wu, José M F Moura, and Soummya Kar. Topology adaptive graph convolutional networks. *ArXiv*, abs/1710.10370, 2017. URL `https://api.semanticscholar.org/CorpusID:27731709`.

[13] X He, J Huang, K Ma, H He, and M Li. An explainable graph neural network framework for illicit financial transaction detection. *Applied Intelligence*, 56(4):102, 2026. doi: 10.1007/s10489-026-07138-9.

[14] A Adadi and M Berrada. Peeking inside the black-box: a survey on explainable artificial intelligence (XAI). *IEEE Access*, 6:52138–52160, 2018. doi: 10.1109/ACCESS.2018.2870052.

[15] Z Ying, D Bourgeois, J You, M Zitnik, and J Leskovec. Gnnexplainer: Generating explanations for graph neural networks. In *Advances in Neural Information Processing Systems*, volume 32, 2019.

[16] D Luo, W Cheng, D Xu, W Yu, B Zong, H Chen, and X Zhang. Parameterized explainer for graph neural network. In *Advances in Neural Information Processing Systems*, volume 33, pages 19620–19631, 2020.

[17] S Akkas and A Azad. Gnnshap: Scalable and accurate gnn explanation using shapley values. In *Proceedings of the ACM Web Conference 2024*, pages 827–838, 2024. doi: 10.1145/3589334.3645599.

[18] F Gawantka, F Just, M Savelyeva, M Wappler, and J Lässig. A novel metric for evaluating the stability of XAI explanations. *Advances in Science, Technology and Engineering Systems Journal*, 9:133–142, 2024. doi: 10.25046/aj090113.

[19] C Agarwal, M Zitnik, and H Lakkaraju. Probing GNN explainers: A rigorous theoretical and empirical analysis of GNN explanation methods. In *International Conference on Artificial Intelligence and Statistics*, pages 8969–8996, 2022. URL `https://proceedings.mlr.press/v151/agarwal22b.html`.

[20] Mert Kosan, Samidha Mridul Verma, Burouj Armgaan, Khushbu Pahwa, Ambuj K Singh, Sourav Medya, and Sayan Ranu. GNNX-BENCH: Unravelling the Utility of Perturbation-based GNN Explainers through In-depth Benchmarking. *ArXiv*, abs/2310.01794, 2023. URL `https://api.semanticscholar.org/CorpusID:263608316`.

[21] W W Lo, G K Kulatilleke, M Sarhan, S Layeghy, and M Portmann. Inspection-L: self-supervised GNN node embeddings for money laundering detection in bitcoin. *Applied Intelligence*, 53(16):19406–19417, 2023. doi: 10.1007/s10489-023-04504-9.

[22] Burouj Armgaan, Eshank Jain, Harsh Pandey, Mahesh Chandran, and Sayan Ranu. GnnXemplar: Exemplars to Explanations - Natural Language Rules for Global GNN Interpretability. *ArXiv*, abs/2509.18376, 2025. URL `https://api.semanticscholar.org/CorpusID:281495990`.

[23] T Rai, J He, J Kaur, Y Shen, M Mahmud, D J Brown, and D Baldwin. Evaluating XAI techniques under class imbalance using CPRD data. *Frontiers in Artificial Intelligence*, 8:1682919, 2025. doi: 10.3389/frai.2025.1682919.

[24] K Fujiwara. Knowledge distillation with resampling for imbalanced data classification: Enhancing predictive performance and explainability stability. *Results in Engineering*, 24:103406, 2024. doi: 10.1016/j.rineng.2024.103406.

[25] T Zhao, X Zhang, and S Wang. Graphsmote: Imbalanced node classification on graphs with graph neural networks. In *Proceedings of the 14th ACM International Conference on Web Search and Data Mining*, pages 833–841, 2021. doi: 10.1145/3437963.3441720.

[26] R S Menezes and H Raimir Filho. Semantic and Structural Drift in Financial Knowledge Graphs: A Robustness Analysis of GNN-Based Fraud Detectors. In *2025 IEEE International Conference on Knowledge Graph (ICKG)*, pages 285–291, 2025. doi: 10.1109/ICKG66886.2025.00044.

[27] UNODC. Estimating Illicit Financial Flows Resulting from Drug Trafficking and Other Transnational Organized Crimes. Technical report, United Nations Office on Drugs and Crime, 2024.

[28] FATF. International Standards on Combating Money Laundering and the Financing of Terrorism & Proliferation (The FATF Recommendations), 2012.

[29] Basel Committee on Banking Supervision. Sound management of risks related to money laundering and financing of terrorism. Technical report, Bank for International Settlements, 2020.

[30] Forrester Consulting. True Cost of Financial Crime Compliance 2023. Technical report, LexisNexis Risk Solutions, 2023.

[31] Chainalysis. The 2025 Crypto Crime Report. Technical report, Chainalysis Inc., 2025.

[32] Europol. EU Serious and Organised Crime Threat Assessment (EU-SOCTA) 2025. Technical report, European Union Agency for Law Enforcement Cooperation, The Hague, Netherlands, 2025.

[33] Thomas N Kipf and Max Welling. Semi-Supervised Classification with Graph Convolutional Networks. In *International Conference on Learning Representations (ICLR)*, 2017.

[34] William L Hamilton, Rex Ying, and Jure Leskovec. Inductive Representation Learning on Large Graphs. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 1024–1034, 2017.

[35] Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò, and Yoshua Bengio. Graph Attention Networks. In *International Conference on Learning Representations (ICLR)*, 2018.

[36] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal Loss for Dense Object Detection. In *IEEE International Conference on Computer Vision (ICCV)*, pages 2980–2988, 2017. doi: 10.1109/ICCV.2017.324.